



UNIVERSIDAD NACIONAL AUTÓNOMA DE MÉXICO

POSGRADO CONJUNTO EN CIENCIAS MATEMÁTICAS
UNAM-UMSNH

IDENTIFICACIÓN DE RECOMBINACIÓN EN VIRUS
UTILIZANDO ANÁLISIS TOPOLÓGICO DE DATOS

T E S I S

PARA OPTAR POR EL GRADO DE:

Maestro en Ciencias Matemáticas

PRESENTA:

Jaime Salvador López Viveros

TUTOR:

Dra. Nelly Sélem Mojica



Morelia, Michoacán, 2025

JURADO ASIGNADO:

Presidente:

Secretario:

Vocal:

1er. Suplente:

2o. Suplente:

La tesis se realizó en .

*Al Posgrado en Conjunto en Ciencias Matemáticas de la UNAM y la Universidad
Michoacana de San Nicolás de Hidalgo, por la formación académica y el apoyo
brindado durante esta etapa de mi vida.
Es gracias a ustedes que este trabajo ha sido posible.
Con gratitud,
Jaime Salvador López Viveros.*

Reconocimientos

Este logro no sería posible sin el amor y el apoyo inquebrantable de mis padres, Jose Jaime López Rodríguez y Maria Icela Viveros Delgadillo. A mi papá, gracias por enseñarme con tu ejemplo que la perseverancia y el trabajo duro siempre dan frutos. A mi mamá, gracias por ser mi apoyo incondicional, por escucharme en los momentos de frustración y por llenarme de ánimo cuando más lo necesitaba. Eres mi ejemplo de amor y sacrificio. Ustedes son mi mayor inspiración y mi razón para seguir adelante. Este título es tan suyo como mío.

A mi asesora, la Doctora Nelly Sélem Mojica, le debo gran parte de este logro. Su paciencia, sabiduría y dedicación no solo me guiaron en este proyecto, sino que también me enseñaron a ser mejor estudiante y profesional. Gracias por creer en mi potencial y por empujarme a dar lo mejor de mí.

También quiero agradecer a las instituciones que hicieron posible este trabajo, en particular a CONACYT por el apoyo financiero que me permitió dedicarme de lleno a esta investigación.

Finalmente, a todos aquellos que, de una manera u otra, estuvieron presentes en este camino: amigos, profesores y familiares. Cada uno de ustedes dejó una huella en este proceso, y por eso les estaré eternamente agradecido.

Declaración de autenticidad

Por la presente declaro que, salvo cuando se haga referencia específica al trabajo de otras personas, el contenido de esta tesis es original y no se ha presentado total o parcialmente para su consideración para cualquier otro título o grado en esta o cualquier otra Universidad. Esta tesis es resultado de mi propio trabajo y no incluye nada que sea el resultado de algún trabajo realizado en colaboración, salvo que se indique específicamente en el texto.

Jaime Salvador López Viveros. Morelia, Michoacán, 2025

Resumen

Los eventos de transferencia genética horizontal son mecanismos evolutivos que permiten el intercambio de material genético entre diferentes linajes virales fuera del proceso normal de replicación. Mientras que en la evolución vertical las variaciones genéticas se acumulan a través de mutaciones durante la replicación del genoma viral, la transferencia genética horizontal permite la adquisición directa de material genético entre virus diferentes que coinfectan la misma célula. En virus, la transferencia genética horizontal ocurre principalmente mediante dos procesos: el reordenamiento genético, donde se intercambian segmentos genómicos completos entre diferentes cepas virales, y la recombinación, donde se intercambian fragmentos de material genético dentro de una misma región del genoma.

Este trabajo replica una metodología basada en el Análisis Topológico de Datos (TDA) para detectar y caracterizar eventos de transferencia genética horizontal en virus (5). La metodología propuesta aprovecha conceptos de topología algebraica, particularmente la homología persistente. Aunque existen librerías como GUDHI que calculan matemáticamente el nacimiento y muerte de estructuras topológicas (componentes conectados, ciclos y cavidades) a diferentes escalas de distancia, carecen de herramientas específicas para identificar y visualizar el momento exacto de formación y desaparición de las estructuras topológicas encontradas, así como para determinar qué elementos del conjunto de datos participan en la formación de estas estructuras topológicas. Por ello, se desarrolló una función para visualizar mejor los 1-hoyos y 2-hoyos (también conocidos como ciclos y cavidades respectivamente), permitiendo detectar simultáneamente múltiples eventos.

El desarrollo fue validado utilizando un caso conocido de reordenamiento triple en el virus H7N9 y fue aplicado al virus SARS-CoV-2 en busca de un evento de recombinación. Se realizaron múltiples experimentos de control negativo para evaluar el método, además de experimentos de simulación para determinar su sensibilidad y robustez. Los resultados demuestran que se pueden detectar eventos de transferencia horizontal y distinguir entre reordenamiento y recombinación mediante patrones topológicos característicos aunque con ciertas limitantes.

Índice general

Índice de figuras	XIII
1. Introducción	1
1.1. Presentación	1
1.2. Objetivo	1
1.3. Motivación	2
1.4. Planteamiento del problema	3
1.5. Contribuciones	3
1.6. Estructura de la tesis	3
2. Fundamentos biológicos	7
2.1. Gen	7
2.2. Genoma	7
2.3. Virus	7
2.4. Genoma de referencia	8
2.5. El virus de influenza	8
2.5.1. Principales proteínas de estudio	8
2.6. Reordenamiento	9
2.7. El virus del Sars Cov2	10
2.7.1. Principales proteínas de estudio	11
2.8. Recombinación	11
3. Fundamentos matemáticos	13
3.1. Análisis Topológico de Datos	13
3.2. Homología persistente	14
3.2.1. Distancia de Hamming	16
3.3. TDA y su aplicación en la detección de transferencia genética horizontal	16
3.3.1. Transformación de secuencias genómicas a estructuras topológicas	18
3.3.1.1. Proceso de transformación	18
4. Metodología	21
4.1. Obtención y preparación de los datos	21
4.1.1. Fuentes de datos	21

ÍNDICE GENERAL

4.1.2.	Requisitos básicos de selección	21
4.1.2.1.	Alineamiento de secuencias	22
4.1.3.	Criterios específicos por experimento	22
4.1.3.1.	Experimento de validación de reordenamiento en H7N9	22
4.1.3.2.	Experimentos de detección con variación del tamaño muestral	23
4.1.3.3.	Experimentos de simulación	24
4.1.3.4.	Experimentos de control negativo	25
4.1.3.5.	Experimento de detección de recombinación en SARS-CoV-2	29
4.2.	Implementación del TDA	30
4.2.1.	Construcción de matrices de distancia	30
4.2.1.1.	Cálculo de distancias	30
4.2.1.2.	Construcción de la matriz	30
4.2.2.	Cálculo de homología persistente	31
4.2.2.1.	Construcción del complejo simplicial	31
4.2.3.	Visualización de resultados	31
4.2.3.1.	Diagramas de persistencia	31
4.2.3.2.	Códigos de barras	31
4.2.3.3.	Mapas de calor	32
4.2.3.4.	Visualización de complejos simpliciales	32
4.2.3.5.	Herramientas y bibliotecas utilizadas	33
5.	Resultados	35
5.1.	Resultados de controles negativos	35
5.1.1.	Comparación entre Influenza A e Influenza B	35
5.1.2.	Análisis de cepas cercanas de H1N1	37
5.1.3.	Análisis de cepas distantes	42
5.2.	Validación de reordenamiento en H7N9	44
5.2.1.	Análisis de segmentos concatenados	44
5.2.1.1.	Análisis de segmentos individuales	47
5.3.	Recombinación en SARS-CoV-2	48
5.3.1.	Análisis de secuencias concatenadas	48
5.3.1.1.	Análisis de segmentos individuales	49
5.4.	Resultados de pruebas de robustez	52
5.4.1.	Análisis de sensibilidad al tamaño muestral	52
5.4.2.	Análisis con secuencias artificiales complementarias	55
5.5.	Resultados de experimentos de simulación	57
5.5.1.	Simulación control	57
5.5.2.	Simulación de reordenamiento	61
5.5.2.1.	Análisis de secuencias concatenadas	61
5.5.2.2.	Análisis de segmentos individuales	62
5.5.3.	Simulación de recombinación	64

5.5.3.1.	Análisis de secuencias concatenadas	64
5.5.3.2.	Análisis de segmentos individuales	65
6.	Discusión	69
6.1.	Análisis de la validación del método	69
6.1.1.	Interpretación de los controles negativos	69
6.1.2.	Robustez y reproducibilidad del método	71
6.1.2.1.	Robustez frente a variaciones en el tamaño muestral . .	71
6.1.2.2.	Reproducibilidad con secuencias artificiales	72
6.1.2.3.	Implicaciones para la aplicación del método	72
6.2.	Interpretación de casos de estudio	74
6.2.1.	Reordenamiento triple en H7N9	74
6.2.1.1.	Análisis de la señal topológica característica	74
6.2.1.2.	Ventajas del método de análisis topológico	74
6.2.2.	Recombinación en SARS-CoV-2	75
6.2.2.1.	Significado biológico de los patrones detectados	75
6.2.3.	Análisis de los experimentos de simulación	76
6.2.3.1.	Validación de las señales topológicas	76
6.2.3.2.	Distinción entre reordenamiento y recombinación	77
6.2.3.3.	Implicaciones para el análisis de eventos de transferen- cia genética	77
6.2.3.4.	Consideraciones sobre la composición de secuencias re- combinantes	78
6.3.	Limitaciones del método	79
6.3.1.	Requerimientos específicos de datos	79
6.3.2.	Limitaciones técnicas	79
6.3.3.	Limitaciones de validación	80
6.3.4.	Evaluación de robustez:	80
6.3.5.	Implicaciones para la aplicación práctica	80
6.4.	Trabajo futuro	80
6.4.1.	Mejoras metodológicas y expansión del alcance	81
6.4.2.	Validación y benchmarking	81
A.	Código y recursos computacionales	83
A.0.1.	Estructura del repositorio	83
	Bibliografía	85

Índice de figuras

2.1. Ejemplo de reordenamiento en virus con genoma segmentado.	10
2.2. Estructura del SARS-CoV-2 mostrando sus principales componentes. . .	12
3.1. Simplejos y complejos simpliciales	15
3.2. Comparación de estructuras evolutivas con y sin transferencia horizontal	17
3.3. Proceso de transformación de secuencias genómicas a estructuras to- pológicas	19
5.1. La homología persistente demuestra la ausencia de transferencia genética horizontal entre virus de Influenza A e Influenza B. Los diagramas de persistencia (izquierda) y códigos de barras (derecha) revelan únicamente componentes conectados (H0) para ambos tipos virales. Las secuencias de Influenza A corresponden a subtipos H1N1 y H3N2 aislados de humanos en China, Estados Unidos y España (2004-2010), mientras que las de Influenza B provienen de aislados humanos de Estados Unidos, Asia y Oceanía (2008-2010).	36
5.2. Visualización tridimensional de los dos agujeros topológicos detectados en el conjunto de 60 secuencias. A la izquierda se muestra el primer ciclo H1 (nacimiento: 40.0, muerte: 41.0) y a la derecha el segundo ciclo H1 (nacimiento: 45.0, muerte: 46.0).	38
5.3. Visualización del agujero topológico para el conjunto de 20 secuencias. .	39
5.4. Visualización tridimensional del agujero topológico para el conjunto de 7 secuencias.	40
5.5. Los diagramas de persistencia (izquierda) y códigos de barras (derecha) muestran los resultados para conjuntos de 100, 60, 20 y 7 secuencias de H1N1.	41
5.6. Visualizaciones del análisis topológico para el conjunto de 37 secuencias de diferentes hospedadores y subtipos.	43
5.7. Visualización del agujero topológico detectado en el conjunto de secuen- cias distantes.	43
5.8. A la izquierda, diagrama de persistencia del análisis de secuencias con- catenadas de H7N9. A la derecha, código de barras correspondiente. Se observa el agujero unidimensional (H1) y el agujero bidimensional (H2). .	44

5.9. Mapa de calor mostrando las distancias genéticas entre las secuencias analizadas.	45
5.10. Visualización tridimensional del complejo simplicial en $\epsilon = 2027$, donde se observa la formación del agujero bidimensional que caracteriza el reordenamiento triple. El simplejo que se forma en ese momento y por el que obtenemos nuestro agujero bidimensional está coloreado de amarillo.	46
5.11. Diagramas de persistencia individuales para cada uno de los ocho segmentos genómicos analizados. Se observa la ausencia de agujeros en todos los segmentos cuando se analizan de manera individual.	47
5.12. Diagramas de persistencia y códigos de barras para el análisis del SARS-CoV-2, mostrando el agujero unidimensional detectado.	49
5.13. Diagramas de persistencia individuales para cada uno de los segmentos que codifican proteínas en el virus SARS-CoV-2. Se observa la presencia de un agujero unidimensional únicamente en el diagrama correspondiente a la proteína Spike (S).	50
5.14. Mapas de calor individuales para cada una de las proteínas del SARS-CoV-2	51
5.15. Análisis de sensibilidad al tamaño muestral. Se muestran los diagramas de persistencia (izquierda) y códigos de barras (derecha) para los distintos conjuntos de datos. La señal del agujero bidimensional (H2) característico del reordenamiento triple se mantiene visible en los conjuntos de 21 y 27 secuencias, pero desaparece en los conjuntos más grandes de 39 y 54 secuencias	54
5.16. Visualizaciones del análisis topológico para el conjunto ampliado con secuencias artificiales (tasa de mutación 2 %). A la izquierda, diagrama de persistencia mostrando los dos agujeros unidimensionales (H1). A la derecha, el código de barras correspondiente.	56
5.17. Visualizaciones del análisis topológico para el conjunto ampliado con secuencias artificiales (tasa de mutación 10 %). A la izquierda, diagrama de persistencia mostrando los siete agujeros unidimensionales (H1). A la derecha, el código de barras correspondiente.	57
5.18. Visualizaciones del análisis topológico para la simulación control. A la izquierda, diagrama de persistencia mostrando únicamente componentes conectados (H0). A la derecha, el código de barras correspondiente.	58
5.19. Visualización tridimensional del complejo simplicial en $\epsilon = 2126$ para la simulación control. Se observa que todas las secuencias están conectadas mediante aristas (1-simplejos), formando una única componente conexa sin agujeros topológicos.	59
5.20. Diagramas de persistencia individuales para cada uno de los ocho segmentos genómicos analizados en la simulación control.	60
5.21. Visualizaciones del análisis topológico para la simulación de reordenamiento. A la izquierda, diagrama de persistencia mostrando el agujero unidimensional (H1). A la derecha, el código de barras correspondiente.	61

5.22. Visualización tridimensional del complejo simplicial en $\epsilon = 2133.0$, donde se observa la formación del agujero unidimensional (H1). Los vértices están coloreados según el subtipo viral: H1N1 en naranja, H3N2 en azul, H1N2 en verde y H3N1 en amarillo.	62
5.23. Diagramas de persistencia individuales para cada uno de los ocho segmentos genómicos analizados en la simulación de reordenamiento. Se observa la ausencia de agujeros en todos los segmentos cuando se analizan de manera individual, incluso en el segmento 4 (HA) que fue el utilizado para generar el reordenamiento.	63
5.24. Visualizaciones del análisis topológico para la simulación de recombinación. A la izquierda, diagrama de persistencia mostrando el agujero unidimensional (H1). A la derecha, el código de barras correspondiente.	64
5.25. Visualización tridimensional del complejo simplicial en $\epsilon = 2126.0$, donde se observa la formación del agujero unidimensional (H1). El ciclo que forma es topológicamente idéntico al detectado en el experimento de reordenamiento.	65
5.26. Diagramas de persistencia del segmento 4 para recombinación (izquierda) y reordenamiento (derecha).	66
5.27. Visualización de los complejos simpliciales en $\epsilon = 650$. En el caso de recombinación (izquierda) se observan dos grupos diferenciados: una arista aislada entre Michigan y Swine, y un prisma triangular formado por las secuencias restantes. En contraste, el reordenamiento (derecha) muestra una única estructura conectada formada por un triángulo (Test-Michigan-Swine) y un tetraedro (secuencias H3N2 y Test), unidos a través del vértice Test.	66
5.28. Diagramas de persistencia del segmento 4 incluyendo A/Test2/?/201?(H1N2). La recombinación (izquierda) muestra un agujero unidimensional característico, mientras que el reordenamiento (derecha) mantiene la ausencia de agujeros topológicos.	67
5.29. Visualización de los complejos simpliciales en $\epsilon = 650$ incluyendo A/Test2/?/201?(H1N2). En el caso de recombinación (izquierda) se observa la formación de un agujero unidimensional formado por las secuencias A/Test2/?/201?(H1N2), A/Test/?/201?(H3N1), A/Swine/Indiana/P12439/00(H1N2), A/Michigan/45/2015(H1N1), A/Hong Kong/1968(H3N2) y A/Perth/16/2009(H3N2). En contraste, el reordenamiento (derecha) mantiene una estructura sin agujeros topológicos.	68

- 6.1. Visualización del efecto de saturación en el espacio métrico al aumentar el tamaño muestral. A la izquierda se muestra un conjunto de 4 secuencias (puntos azules) que forman un ciclo para un valor dado de ϵ . A la derecha se ilustra cómo la adición de una quinta secuencia (punto rojo) en el centro actúa como “puente”, generando múltiples triángulos que interrumpen la formación del ciclo original. Este fenómeno explica por qué las señales topológicas pueden perderse al aumentar el número de secuencias en el análisis: los nuevos puntos pueden ubicarse en posiciones que interrumpen las estructuras topológicas previamente detectables. . . 73

Introducción

1.1. Presentación

La transferencia genética horizontal en virus representa uno de los mecanismos más importantes en su evolución, permitiéndoles adquirir nuevas características y adaptarse rápidamente a diferentes entornos. En el caso específico de los virus de influenza y SARS-CoV-2, esta transferencia ocurre principalmente a través de dos mecanismos: el reordenamiento, que involucra el intercambio de segmentos genómicos completos entre virus segmentados, y la recombinación, que implica el intercambio de material genético dentro de un mismo segmento.

La detección y caracterización de estos eventos de transferencia horizontal es de suma importancia para comprender la evolución viral y anticipar posibles amenazas emergentes.

El presente trabajo introduce una nueva aproximación basada en el Análisis Topológico de Datos (TDA) para la detección de eventos de transferencia genética horizontal en virus. Esta metodología aprovecha conceptos fundamentales de la topología algebraica, particularmente la homología persistente, para identificar y caracterizar patrones estructurales en datos genómicos que son indicativos de eventos de transferencia horizontal.

El enfoque topológico propuesto permite detectar simultáneamente múltiples eventos de transferencia horizontal y distinguir entre diferentes tipos de eventos mediante el análisis de sus características topológicas distintivas.

1.2. Objetivo

El objetivo principal de este trabajo es identificar eventos de transferencia genética horizontal en genomas virales mediante la detección de 1-hoyos y 2-hoyos utilizando Análisis Topológico de Datos, a través del desarrollo de scripts que faciliten la visualización de estas estructuras topológicas, con énfasis particular en los virus de influenza

1. INTRODUCCIÓN

y SARS-CoV-2.

Los objetivos específicos que se derivan del objetivo general son:

1. Implementar un método de análisis basado en homología persistente que permita:
 - Replicar la identificación de eventos de reordenamiento en virus con genoma segmentado, particularmente en el virus de la influenza
 - Identificar eventos de recombinación en virus con genoma no segmentado, específicamente en SARS-CoV-2
 - Distinguir entre diferentes tipos de transferencia genética horizontal mediante el análisis de sus características topológicas
2. Validar la efectividad del método mediante:
 - Análisis de casos conocidos de reordenamiento triple en el virus H7N9
 - Estudio de eventos documentados de recombinación en variantes de SARS-CoV-2
 - Realización de experimentos de control negativo para evaluar la especificidad del método
3. Evaluar la robustez y reproducibilidad del método a través de:
 - Análisis de sensibilidad al tamaño muestral
 - Experimentos con secuencias artificiales complementarias
 - Simulaciones controladas de eventos de transferencia genética
4. Desarrollar herramientas computacionales que permitan visualizar y analizar los resultados de manera intuitiva

1.3. Motivación

La comprensión de los mecanismos de evolución viral, particularmente la transferencia genética horizontal, es fundamental para la salud pública global. Los eventos de reordenamiento y recombinación pueden dar lugar a nuevas variantes virales con características alteradas, incluyendo cambios en su patogenicidad, rango de hospedadores o capacidad de evasión inmune. La pandemia de influenza H1N1 de 2009 y la emergencia de variantes recombinantes de SARS-CoV-2 durante la pandemia de COVID-19 son ejemplos claros de cómo estos eventos pueden tener impactos significativos en la salud pública mundial.

1.4. Planteamiento del problema

La evolución viral representa un desafío significativo para la salud pública global debido a la velocidad con que estos patógenos pueden adquirir nuevas características. La transferencia genética horizontal acelera aún más este proceso evolutivo, permitiendo que los virus adquieran material genético de diferentes linajes de manera directa, lo que puede resultar en la emergencia de nuevas variantes con características alteradas de patogenicidad, rango de hospedadores o capacidad de evasión inmune. La detección y caracterización oportuna de estos eventos de transferencia horizontal es importante para comprender y anticipar posibles amenazas virales emergentes.

1.5. Contribuciones

Se ha replicado una metodología que utiliza homología persistente para detectar y analizar eventos de transferencia genética horizontal en virus. Además se incluyó el diseño de protocolos de validación mediante controles negativos y experimentos de simulación. Los resultados obtenidos han permitido lograr la validación topológica del reordenamiento triple en el virus H7N9. A través de la caracterización de patrones topológicos distintivos asociados con diferentes tipos de transferencia genética horizontal, se han identificado señales específicas que permiten diferenciar entre eventos de reordenamiento y recombinación. En el ámbito técnico, se han implementado herramientas de visualización especializadas, las cuales permiten una interpretación más intuitiva y efectiva de las estructuras topológicas detectadas. Estas herramientas facilitan la identificación y caracterización de eventos de transferencia horizontal, proporcionando una interfaz accesible. Se han establecido criterios rigurosos para evaluar la robustez y confiabilidad de las señales topológicas detectadas. El trabajo también ha permitido identificar limitaciones y consideraciones prácticas para la aplicación del método en diferentes contextos. Esta comprensión de las limitaciones y fortalezas del método es importante para su aplicación efectiva en el estudio de la evolución viral y la detección temprana de nuevas variantes potencialmente significativas.

1.6. Estructura de la tesis

Esta tesis está organizada en seis capítulos principales, además de un apéndice que contiene material complementario. A continuación se describe el contenido de cada capítulo:

1. Capítulo 1: Introducción

Presenta el contexto general del trabajo, establece los objetivos principales y específicos, expone la motivación y relevancia del estudio, y plantea el problema

1. INTRODUCCIÓN

a abordar. También describe las principales contribuciones y la estructura general del documento.

2. Capítulo 2: Fundamentos biológicos

Introduce los conceptos biológicos fundamentales necesarios para comprender el trabajo, incluyendo:

- Conceptos básicos sobre virus y evolución viral
- Características específicas de los virus de influenza y SARS-CoV-2
- Mecanismos de transferencia genética horizontal: reordenamiento y recombinación
- Importancia de estos procesos en la evolución viral

3. Capítulo 3: Fundamentos matemáticos

Establece el marco teórico del Análisis Topológico de Datos, abordando:

- Principios básicos del TDA
- Teoría de la homología persistente
- Aplicación del TDA al análisis genómico
- Transformación de secuencias genómicas a estructuras topológicas

4. Capítulo 4: Metodología

Detalla los procedimientos y métodos empleados en el estudio:

- Obtención y preparación de datos genómicos
- Implementación del análisis topológico
- Diseño de experimentos de validación
- Desarrollo de herramientas computacionales

5. Capítulo 5: Resultados

Presenta los hallazgos principales del estudio, incluyendo:

- Resultados de los controles negativos
- Validación del reordenamiento triple en H7N9
- Análisis de recombinación en SARS-CoV-2
- Resultados de las pruebas de robustez y simulaciones

6. Capítulo 6: Discusión

Analiza e interpreta los resultados obtenidos, abordando:

- Análisis de la validación del método
- Interpretación de los casos de estudio
- Limitaciones identificadas

- Perspectivas y trabajo futuro

7. Apéndice

Proporciona material complementario importante:

- Códigos y scripts desarrollados
- Detalles técnicos de implementación
- Listado completo de secuencias utilizadas

Fundamentos biológicos

2.1. Gen

Un gen es una secuencia específica de ADN o ARN que codifica las instrucciones para producir una proteína u otra molécula funcional. Los genes son las unidades básicas de la herencia y contienen la información necesaria para determinar características específicas de un organismo (36). En el caso de los virus, los genes codifican las proteínas necesarias para la infección, replicación y ensamblaje de nuevas partículas virales.

2.2. Genoma

El conjunto completo de genes se llama genoma. En la gran mayoría de organismos está compuesto por moléculas de ADN, sin embargo en algunos virus, su material genético está compuesto por moléculas de ARN en lugar de ADN.(2) Ejemplo de esto es el virus de la influenza.

En este trabajo se analizarán genomas de virus, específicamente de influenza y SARS-CoV-2. El genoma viral contiene toda la información genética necesaria para que el virus crezca, se replique y pueda continuar transmitiéndose de célula a célula.

Existen varios repositorios públicos que se encargan de recolectar, mantener y preservar las secuencias genómicas de virus para su estudio por parte de la comunidad científica.

2.3. Virus

Un virus es un parásito intracelular infeccioso. Estos utilizan la maquinaria de las células huésped para dirigir la síntesis de sus componentes y ensamblar nuevas partículas virales infecciosas (viriones) que pueden transmitir el genoma viral e iniciar nuevos ciclos de infección en otros huéspedes.(10)

2.4. Genoma de referencia

Una secuencia de referencia es una representación aceptada que es utilizada por los investigadores como estándar para la comparación con otras secuencias generadas. (13) Esta secuencia de referencia es obtenida mediante el mapeo de miles de muestras individuales. En el caso del virus del SARS-CoV-2 el primer genoma de referencia obtenido fue reportado en enero 2020 por Zhu et al, sobre la base de muestras iniciales del brote en Wuhan. Este se ha venido actualizando con la incorporación de nuevas variantes (41)

2.5. El virus de influenza

Los virus influenza son un tipo de virus segmentado perteneciente a la familia Orthomyxoviridae (17). Hay cuatro tipos de virus de la influenza: A, B, C y D. Solo los virus A y B son los causantes de epidemias estacionales de la enfermedad en las personas.

El genoma del virus influenza A consta de 8 segmentos de ARN de sentido negativo que codifican para 10 proteínas virales. Entre estas proteínas se incluyen glicoproteínas de superficie, proteínas estructurales y proteínas implicadas en la replicación viral (7).

Existen 18 subtipos diferentes de hemaglutinina (HA) y 11 subtipos de neuraminidasa (NA). Los subtipos son designados mediante la combinación de las cantidades de H y N, esto permite categorizarlos y estudiar sus características específicas (3).

La distribución de los subtipos de influenza varía según el hospedador. Los virus humanos poseen las combinaciones de H1, H2, H3 y N1 y N2, las cuales se comparten con los cerdos. Otros subtipos como H5, H6, H7, H9 y N1, N2, N3, N7, solo circulan en aves de corral, mientras que las ballenas y gaviotas tienen H13, N2, N6. Todos los tipos, subtipos y variantes se encuentran en las aves migratorias y silvestres.

Aunque se han identificado más de 130 combinaciones de subtipos de influenza A, es posible que existan muchas más combinaciones gracias a una característica compartida de los virus de ARN segmentados conocido como reordenamiento (35), cuya definición se abordará más adelante.

2.5.1. Principales proteínas de estudio

- **Hemaglutinina (HA):** Esta glicoproteína de superficie se une a los receptores de ácido siálico en las células huésped, facilitando la entrada del virus. Es el principal objetivo de los anticuerpos neutralizantes.
- **Neuraminidasa (NA):** Esta enzima de superficie ayuda a liberar las nuevas partículas virales de las células infectadas cortando los residuos de ácido siálico.

- **Proteína de la matriz (M1):** Forma la capa estructural debajo de la envoltura viral y juega un papel crucial en el ensamblaje y la liberación del virus.
- **Proteína de canal iónico (M2):** Forma canales de protones en la envoltura viral, esenciales para la desencapsidación del virus después de la entrada.
- **Nucleoproteína (NP):** Se une al ARN viral y es esencial para la transcripción, replicación y empaquetamiento del genoma viral.
- **Proteínas del complejo de la polimerasa (PA, PB1, PB2):** Forman el complejo de la ARN polimerasa viral, responsable de la transcripción y replicación del genoma viral.

(7)

Estas proteínas trabajan en conjunto para permitir la entrada del virus en las células huésped, su replicación y la liberación de nuevas partículas virales. La hemaglutinina y la neuraminidasa, en particular, son las principales determinantes antigénicas y juegan un papel crucial en la interacción del virus con el sistema inmune del huésped (7).

En el contexto de este trabajo, cuando nos referimos a transferencia genética horizontal en virus, nos limitamos específicamente a dos mecanismos: el reordenamiento, y la recombinación cuyas definiciones y características se detallan en las siguientes secciones.

2.6. Reordenamiento

El reordenamiento es el proceso mediante el cual dos o más virus intercambian segmentos de genes, esto ocurre cuando dos virus parcialmente diferentes coinfectan una célula (33). Decimos parcialmente diferentes pues un reordenamiento exitoso entre dos cepas parentales requiere de un alto grado de compatibilidad genética. De hecho, no hay registrado algún caso en el que haya ocurrido reordenamiento entre virus de ARN segmentados que pertenezcan a diferentes familias.(21)

Durante la replicación viral dentro de la célula, los segmentos genómicos de los diferentes virus parentales se mezclan y se empaquetan al azar en las nuevas partículas virales que se están formando. Como resultado, se genera una descendencia viral híbrida que puede contener una combinación única de segmentos genéticos derivados de los virus originales que co-infectaron la célula. (21)

Este proceso al darle a un virus contenido genético derivados de más de un progenitor, confiere potencialmente importantes ventajas o desventajas de aptitud a la progenie viral (20) lo que promueve la evolución de los virus de influenza, llegando a causar efectos como nuevas cepas con la capacidad de evadir la respuesta inmune del huésped ,adquirir resistencia a antivirales e inclusive puede permitir a los virus infectar nuevas especies hospedadoras. (23). (12)




Figura 2.1: Ejemplo de reordenamiento en virus con genoma segmentado.

2.7. El virus del Sars Cov2

El SARS-CoV-2 es un nuevo coronavirus que emergió a finales de 2019 en la ciudad de Wuhan, China, y es el agente causal de la enfermedad por coronavirus 2019 (COVID-19). Este virus altamente transmisible y patógeno generó una pandemia que amenazó la salud humana y la seguridad pública a nivel global. La Organización Mundial de la Salud declaró oficialmente pandemia de COVID-19 el 11 de marzo de 2020 (16).

Pertenece a la familia Coronaviridae, específicamente a la subfamilia Orthocoronavirinae dentro del género Betacoronavirus. Está estrechamente relacionado con el coronavirus del SARS (SARS-CoV) que causó la epidemia de SARS en 2002-2003, compartiendo aproximadamente un 79 % de genoma (16, 41).

Aunque la evidencia genética sugiere que el SARS-CoV-2 es un virus de origen natural que probablemente se originó en animales, aún no hay una conclusión sobre cuándo y dónde entró por primera vez en los humanos (41).

De manera similar al proceso de reordenamiento en la influenza, en el virus del Sars Cov2 existe un proceso llamado recombinación.

2.7.1. Principales proteínas de estudio

- **Proteína S (spike)**: Esta proteína forma los picos que sobresalen de la superficie del virus. Permite que el virus se una a las células humanas para infectarlas. Coordinadas de Secuencia de Codificación de Proteínas (21563-25384)
- **Proteína M (membrana)**: Esta proteína forma la envoltura que rodea al material genético del virus. Desempeña un papel importante en el ensamblaje y liberación de partículas virales. Coordinadas de Secuencia de Codificación de Proteínas (26523-27191)
- **Proteína E (envoltura)**: Es una pequeña proteína de membrana involucrada en el ensamblaje y liberación de nuevas partículas virales. Coordinadas de Secuencia de Codificación de Proteínas (26245-26472)
- **Proteína N (nucleocápside)**: Se une al material genético viral (ARN) y lo protege dentro de la nucleocápside. Coordinadas de Secuencia de Codificación de Proteínas (28274-29533)

(26) (19)

2.8. Recombinación

La recombinación, al igual que el reordenamiento, es un proceso fundamental en la evolución viral que permite el intercambio de material genético entre diferentes genomas virales (27). Este fenómeno ocurre cuando al menos dos genomas virales co-infectan la misma célula huésped e intercambian partes de genes o secuencias del mismo segmento (27, 34). A diferencia del reordenamiento, que solo ocurre en virus con genoma segmentado, la recombinación puede darse tanto en virus con genoma segmentado como en aquellos con genoma no segmentado.

La recombinación está íntimamente ligada a la replicación viral. En virus de ADN, ocurre durante la replicación del ADN e implica tanto proteínas virales como celulares (34). En virus de ARN, está generalmente asociada con el proceso de síntesis de ARN viral. El modelo más aceptado es el de "elección de copia", donde la ARN polimerasa viral cambia de molde durante la síntesis (18, 39). Este proceso requiere suficiente similitud de secuencia entre los genomas parentales para permitir el apareamiento de bases y la continuación de la síntesis (39).

La frecuencia de recombinación varía ampliamente entre los virus. Por ejemplo, el virus SARS-CoV-2 tiene tasas de recombinación moderadamente altas, aunque no tan elevadas como las de los alfa herpesvirus (19, 27, 39).

La recombinación tiene importantes implicaciones evolutivas y epidemiológicas. Puede generar nuevas variantes virales con propiedades alteradas, como cambios en el tropismo celular, la virulencia o la capacidad de evadir la respuesta inmune del huésped




Figura 2.2: Estructura del SARS-CoV-2 mostrando sus principales componentes. En la parte central del virus se observa el ARN viral asociado a la proteína de la nucleocápside (N). En la periferia se encuentran los trómeros de la glicoproteína S (spike) que forman los característicos picos, junto con las proteínas de membrana (M) y las proteínas de envoltura (E). Fuente: "Fphar-11-00937-g001" por Colin D. Funk, Craig Laferrière, y Ali Ardakani. Gráfico por Ian Dennis - <http://www.iandennisgraphics.com>, CC BY 4.0, via Wikimedia Commons, <https://commons.wikimedia.org/wiki/File:Fphar-11-00937-g001.jpg>. Imagen recortada.

(27, 39). También puede facilitar la adaptación viral a nuevos huéspedes y ambientes (27).

Fundamentos matemáticos

3.1. Análisis Topológico de Datos

El Análisis Topológico de Datos (TDA, por sus siglas en inglés) es una colección de métodos que buscan encontrar y cuantificar estructura en los datos utilizando conceptos de la topología. El TDA se basa en la idea de que los datos tienen una "forma" que puede ser analizada rigurosamente para obtener información valiosa (38).

Los métodos de TDA incluyen:

1. Agrupamiento (clustering): Quizás la forma más simple y antigua de TDA, el agrupamiento busca identificar grupos naturales en los datos. Los métodos basados en densidad, como el agrupamiento por nivel de densidad, tienen una clara conexión con la topología (38).
2. Estimación de variedades (manifold estimation): Estos métodos asumen que los datos de alta dimensión yacen cerca de una variedad de menor dimensión, y buscan estimar esta estructura subyacente (38).
3. Reducción no lineal de dimensionalidad: Técnicas como Isomap o mapas de difusión que intentan preservar la estructura topológica de los datos al proyectarlos en un espacio de menor dimensión (22).
4. Estimación de modos y crestas: Métodos que buscan identificar características de alta densidad en los datos, como modos (máximos locales de densidad) o crestas (curvas o superficies de alta densidad) (38).
5. Homología persistente: Una técnica central en TDA que estudia cómo evolucionan las características topológicas (como componentes conectados, ciclos, o cavidades) a diferentes escalas (22).

El TDA ofrece varias ventajas sobre los métodos tradicionales de análisis de datos. Es insensible a la elección específica de coordenadas y puede manejar datos con rui-

do. Además, proporciona una forma de resumir y visualizar datos complejos de alta dimensión (22).

Las técnicas de TDA han demostrado ser herramientas muy útiles. En la actualidad se han encontrado varias aplicaciones en diversos campos, desde la biología y la neurociencia hasta la astrofísica y el análisis de imágenes. (1, 15, 22, 32, 38).

En la siguientes sección, profundizaremos en la técnica clave de este proyecto, la homología persistente, una de las herramientas centrales del TDA.

3.2. Homología persistente

La homología persistente es una herramienta fundamental del análisis topológico de datos que permite estudiar las características topológicas de un objeto a múltiples escalas.(28) A diferencia de la homología clásica, la homología persistente captura los cambios en la homología a medida que el objeto evoluciona con respecto a un parámetro.(11)

La homología persistente se construye sobre la noción de complejos simpliciales, que son generalizaciones de grafos que incluyen componentes de dimensiones superiores. Un simplejo es el bloque constructor básico de un complejo simplicial. Formalmente, un k -simplejo es la envolvente convexa de $k+1$ puntos afinmente independientes en un espacio euclídeo (8). Por ejemplo, un 0-simplejo es un punto, un 1-simplejo es una arista que conecta dos puntos, un 2-simplejo es un triángulo lleno, un 3-simplejo es un tetraedro sólido, y así sucesivamente.

Dada una filtración, es decir, una secuencia finita de complejos simpliciales anidados, la homología persistente rastrea las clases de homología que aparecen y desaparecen a lo largo de la filtración.(11).

Cada clase de homología tiene un tiempo de nacimiento (cuando aparece por primera vez), y un tiempo de muerte (cuando desaparece). La persistencia de una clase de homología, dada por la diferencia entre su tiempo de muerte y nacimiento, mide su relevancia dentro de la estructura topológica global del objeto.

La información capturada por la homología persistente se puede visualizar mediante códigos de barras (barcodes) o diagramas de persistencia. En un código de barras, cada barra representa una característica topológica, y la posición y longitud de la barra indican el rango de escalas en el que la característica está presente. En un diagrama de persistencia, cada punto representa una característica topológica, donde la coordenada x es el tiempo de nacimiento y la coordenada y es el tiempo de muerte. En ambos casos, las características con mayor persistencia se consideran más relevantes.(28)

(11) En el contexto del análisis de datos genómicos, la homología persistente provee un enfoque para estudiar la evolución horizontal. (30)(5)(31). El espacio de posibles secuencias genéticas se puede ver como un objeto topológico de alta dimensión, donde cada secuencia es un punto. Bajo la suposición de que cada sitio genético muta a lo más una vez en la historia evolutiva de la muestra, la única forma de crear ciclos en este espacio es a través de eventos de recombinación que combinan mutaciones provenientes




Figura 3.1: Simplejos y complejos simpliciales. La parte superior muestra ejemplos de k -simplejos, desde un 0-simplejo (punto) hasta un 3-simplejo (tetraedro). La parte inferior ilustra dos complejos simpliciales contruidos, podemos notar como dependiendo del radio r de los círculos amarillos va variando el complejo simplicial que obtendremos

de distintos linajes. Por lo tanto, los ciclos detectados por homología persistente a diferentes resoluciones capturan la presencia de recombinación ancestral en la muestra (5).

Así, cada objeto de dimensión uno encontrado en los códigos de barras o en los diagramas de persistencia nos representa un evento de recombinación, donde los tiempos de nacimiento y muerte indican las distancias genéticas entre las secuencias parentales involucradas (30).

Los números de Betti, denotados como b_k cuentan el número de ciclos independientes de dimensión k . Intuitivamente, b_0 cuenta el número de componentes conectados, b_1 cuenta los ciclos o “agujeros” unidimensionales, b_2 cuenta las cavidades o “vacíos” bidimensionales, y así sucesivamente (28). En el análisis de datos genómicos, los números de Betti tienen una interpretación biológica. b_0 captura el número de linajes o componentes distintos en la muestra. b_1 y números de Betti de orden superior cuentan eventos de recombinación ancestral, donde secuencias de diferentes linajes se

han mezclado (30)(5)(31). Específicamente, b_1 cuenta eventos de recombinación que involucran dos secuencias parentales, b_2 cuenta eventos que involucran tres secuencias parentales, y así sucesivamente (5)(31). De esta manera, los números de Betti proveen una descripción topológica de la complejidad de la historia evolutiva de la muestra.

3.2.1. Distancia de Hamming

La distancia de Hamming es una medida para la comparación de cadenas de caracteres. Específicamente la distancia de Hamming entre dos secuencias de caracteres es el número de posiciones en las que los caracteres difieren. (37) En el contexto de secuencias genómicas, esta distancia nos permite cuantificar las diferencias entre secuencias mediante el conteo del número de posiciones en las que los nucleótidos difieren. Por ejemplo, si tenemos dos secuencias de ADN, la distancia de Hamming nos indicará en cuántas posiciones encontramos diferentes nucleótidos (A, T, C o G) al comparar ambas secuencias.

Formalmente, dadas dos secuencias genómicas de longitud K , la distancia de Hamming se define como el número de posiciones en las que las secuencias difieren.

$$D_{ij} = \sum_{l=1}^K \mathbb{I}(X_{il} \neq X_{jl}), \quad (3.1)$$

donde:

- D_{ij} es la distancia de Hamming entre las secuencias i y j
- X_{il} representa el nucleótido en la posición l de la secuencia i
- X_{jl} representa el nucleótido en la posición l de la secuencia j
- $\mathbb{I}(\cdot)$ es la función indicadora que toma el valor 1 cuando los nucleótidos en la posición l son diferentes y 0 cuando son iguales

3.3. TDA y su aplicación en la detección de transferencia genética horizontal

La aplicación del Análisis Topológico de Datos para detectar eventos de transferencia genética horizontal se fundamenta en un principio clave: bajo el supuesto de que cada sitio genético muta a lo más una vez en la historia evolutiva de la muestra, la única forma de crear ciclos o “agujeros” en el espacio de secuencias es a través de eventos de transferencia horizontal que combinan mutaciones provenientes de distintos linajes (30).

Cuando la evolución es puramente vertical, la estructura resultante puede representarse como un árbol que, topológicamente, puede ser “comprimido” a un único punto

sin destruir ninguna característica esencial de su estructura. Sin embargo, cuando ocurren eventos de transferencia horizontal (como recombinación o reordenamiento), se generan estructuras reticuladas que contienen ciclos. Estos ciclos no pueden eliminarse mediante deformación continua sin destruir información fundamental sobre las relaciones evolutivas (30).




Figura 3.2: Comparación de estructuras evolutivas. (A) Un árbol filogenético que representa evolución puramente vertical, el cual puede ser comprimido topológicamente a un punto sin perder información estructural. (B) Una estructura reticulada que representa evolución con transferencia horizontal, donde se observa la formación de un ciclo o “agujero” que no puede eliminarse sin perder información evolutiva fundamental. Este ciclo surge de la combinación de material genético proveniente de diferentes linajes (30).

La homología persistente permite detectar y cuantificar estos ciclos a diferentes escalas evolutivas (30):

- Los números de Betti de dimensión 0 (b_0) capturan el número de linajes o componentes distintos en la muestra
- Los números de Betti de dimensión 1 (b_1) cuentan eventos de transferencia horizontal que involucran dos secuencias parentales
- Los números de Betti de dimensión superior (b_2 , b_3 , etc.) identifican eventos más complejos que involucran múltiples secuencias parentales

3.3.1. Transformación de secuencias genómicas a estructuras topológicas

Para aplicar el análisis topológico a datos genómicos, es necesario trasladar la información biológica a un contexto matemático adecuado para su análisis. Esto se logra representando las secuencias biológicas como puntos en un espacio métrico, donde las distancias entre puntos reflejan las diferencias genéticas entre las secuencias. Este proceso nos permite identificar y estudiar los eventos de transferencia genética horizontal a través de sus características topológicas (30).

3.3.1.1. Proceso de transformación

1. Construcción de la representación topológica:

- Partimos de un conjunto de secuencias genómicas
- Calculamos las distancias genéticas entre cada par de secuencias usando distancia de Hamming. Este valor se guarda en una matriz de distancias.
- Representamos cada genoma como un punto en un espacio métrico, utilizando la matriz de distancias
- Las distancias entre puntos reflejan las diferencias genéticas entre secuencias

2. Aplicación de homología persistente:

- Construimos complejos simpliciales a diferentes escalas
- Conectamos puntos (genomas) que están a una distancia menor que un umbral ϵ , en otras palabras conectamos puntos dependiendo del valor ϵ que tenga el radio de su bola correspondiente.
- Observamos cómo evoluciona la estructura topológica al variar ϵ

3. Análisis de la estructura resultante:

- Identificamos la formación de agujeros a diferentes escalas
- Analizamos la persistencia de estas características topológicas
- Interpretamos el significado biológico de las estructuras encontradas




Figura 3.3: Visualización del proceso de transformación de secuencias genómicas a estructuras topológicas. A la izquierda, se muestran los genomas como puntos aislados. En el centro, estos puntos se ubican en un espacio métrico según sus distancias genéticas. A la derecha, se forman las conexiones entre puntos cercanos, revelando la estructura topológica subyacente que puede contener información sobre eventos de transferencia horizontal.

Metodología

4.1. Obtención y preparación de los datos

4.1.1. Fuentes de datos

En este trabajo se utilizaron dos bases de datos principales para la obtención de secuencias genómicas virales: NCBI Virus Database para las secuencias de influenza y GISAID para las secuencias de SARS-CoV-2. A continuación se describe cada una de ellas en detalle:

- **NCBI Influenza Virus Database:** Esta base de datos del Centro Nacional para la Información Biotecnológica (NCBI) de Estados Unidos contiene más de 500,000 secuencias genómicas de virus influenza de diferentes tipos, subtipos y hospedadores. Permite hacer búsquedas y descargas de secuencias.(24)
- **GISAID:** La Iniciativa Global para Compartir Todos los Datos sobre Influenza (GISAID) es una plataforma que promueve el intercambio internacional de datos genómicos y clínicos sobre los virus influenza. Durante la pandemia de COVID-19, GISAID también se ha convertido en el principal repositorio de secuencias genómicas del SARS-CoV-2 compartidas por científicos de todo el mundo. A mayo de 2023, GISAID alberga más de 14 millones de secuencias genómicas de SARS-CoV-2.(14)

4.1.2. Requisitos básicos de selección

Se establecieron los siguientes requisitos mínimos que debían cumplir todas las secuencias utilizadas en los diferentes experimentos:

- **Compleitud del genoma:** Se seleccionaron únicamente secuencias con una cobertura del 100 % del genoma. Para el virus de la influenza, esto significa contar con los ocho segmentos completos que componen su genoma. En el caso del SARS-CoV-2, se requirió el genoma completo de aproximadamente 30,000 nucleótidos.

4. METODOLOGÍA

- **Formato de datos:** Todas las secuencias fueron descargadas y procesadas en formato FASTA, que proporciona tanto la secuencia de nucleótidos como información básica de identificación en el encabezado.

4.1.2.1. Alineamiento de secuencias

El proceso de alineamiento se realizó utilizando dos herramientas diferentes: Clustal Omega (9) para los virus de Influenza A y los experimentos de control negativo, y NextClade para SARS-CoV-2 (25).

La implementación de Clustal Omega se realizó de dos formas:

1. A través de su interfaz web proporcionada por el Instituto Europeo de Bioinformática (EMBL-EBI)
2. En Python mediante la librería Biopython (6)

En ambos casos se utilizaron los parámetros por defecto del algoritmo. Para los virus de Influenza A, debido a su naturaleza segmentada, cada segmento del genoma se alineó por separado.

En el caso del SARS-CoV-2, se realizó el alineamiento utilizando la secuencia de referencia de Wuhan como base.

Todos los alineamientos resultantes se guardaron en formato FASTA para su posterior análisis.

4.1.3. Criterios específicos por experimento

4.1.3.1. Experimento de validación de reordenamiento en H7N9

Para investigar el evento de reordenamiento triple en H7N9, se seleccionaron seis secuencias virales específicas basadas en estudios previos que sugerían su participación en este evento (5, 12, 40). Las secuencias seleccionadas fueron:

- A/brambling/Beijing/16/2012(H9N2) - *Pinzón real*
- A/quail/Lebanon/273/2010(H9N2) - *Codorniz*
- A/quail/Wuxi/7/2010(H9N2) - *Codorniz*
- A/Shanghai/02/2013(H7N9) - *Humano*
- A/wild bird/Korea/A14/2011(H7N9) - *Ave silvestre*
- A/duck/Zhejiang/10/2011(H7N3) - *Pato*

4.1.3.2. Experimentos de detección con variación del tamaño muestral

Partiendo de las seis secuencias del experimento de validación se realizó un análisis para evaluar el impacto del tamaño muestral en la detección del agujero bidimensional característico del reordenamiento triple en H7N9, utilizando cuatro conjuntos diferentes de datos:

- **Conjunto uno (21 secuencias)**

- Por cada subtipo (H9N2, H7N3 y H7N9) se agregaron 5 secuencias de origen aviar
- Marco temporal: 2010-2013
- Distribución geográfica: provincias de China (Jiangxi, Jiangsu, Zhejiang, Henan) y Corea

- **Conjunto dos (27 secuencias)**

- Por cada subtipo se agregaron:
 - 5 secuencias de origen aviar:
 - ◇ Marco temporal: 2010-2013
 - ◇ Distribución geográfica: provincias de China (Yunnan, Hong Kong, Jiangxi, Shandong, Henan, Fujian) y Corea
 - 2 secuencias de origen humano:
 - ◇ Marco temporal: 2004-2017
 - ◇ Distribución geográfica: China (Beijing, Hunan, Guangdong), Canadá y México

- **Conjunto tres (39 secuencias)**

- Por cada subtipo se agregaron:
 - 8 secuencias de origen aviar con:
 - ◇ Marco temporal: 2010-2013
 - ◇ Distribución geográfica en China (Yangzhou, Jiangxi, Hong Kong, Shandong, Henan), otros países asiáticos (Corea, Emiratos Árabes Unidos) y región del Cáucaso (Georgia)
 - 3 secuencias de origen humano con:
 - ◇ Marco temporal: 2004-2015
 - ◇ Distribución geográfica en China (Hong Kong, Hunan, Guangdong, Xuzhou) y otros países (Taiwán, Canadá, México)

- **Conjunto cuatro (54 secuencias)**

- Por cada subtipo se agregaron:
 - 13 secuencias de origen aviar con:

- ◊ Marco temporal: 2010-2013
- ◊ Distribución geográfica en China (Jiangxi, Hebei, Jiangsu, Hong Kong, Zhejiang, Shanghai, Fujian, Hainan, Yunnan), otros países asiáticos (Corea, Israel) y región del Cáucaso (Georgia)
- 5 secuencias de origen humano con:
 - ◊ Marco temporal: 2004-2017
 - ◊ Distribución en China (Shanghai, Guangdong, Huizhou, Beijing, Hunan, Jiangsu) y otros países (Canadá, México)

4.1.3.3. Experimentos de simulación

Para evaluar la capacidad del método para detectar y diferenciar distintos tipos de eventos de transferencia genética horizontal, específicamente entre reordenamiento y recombinación, se diseñaron tres simulaciones controladas. El objetivo principal fue determinar si el análisis topológico podía distinguir las diferentes características estructurales que emergen de cada tipo de transferencia horizontal, ya que el reordenamiento involucra el intercambio de segmentos completos mientras que la recombinación implica el intercambio de material genético dentro de un mismo segmento. Para esto, se utilizaron cinco secuencias base:

■ Conjunto base de secuencias:

- A/Michigan/45/2015(H1N1) - *Humano*
- A/Swine/Indiana/P12439/00(H1N2) - *Cerdo*
- A/Perth/16/2009(H3N2) - *Humano*
- A/Hong Kong/1968(H3N2) - *Humano*
- A/Victoria/361/2011(H3N2) - *Humano*

Se realizaron tres tipos de experimentos:

1. Simulación control

- Uso de secuencias originales sin modificaciones
- Marco temporal: 2009-2015
- Distribución geográfica: Estados Unidos, Hong Kong, Perth, Victoria

2. Simulación de reordenamiento

- Se generó una variante híbrida ('A/Test/?/201?(H3N1)') combinando:
 - Segmento 4 (HA) de A/Hong Kong/1968(H3N2)
 - Demás segmentos de A/Michigan/45/2015(H1N1)

3. Simulación de recombinación

- Se creó una variante artificial 'A/Test/?/201?(H3N1)' con los mismos parentales anteriores, pero en este caso todos los segmentos son de A/Michigan/45/2015(H1N1) excluyendo el segmento 4, que esta compuesto por parte de A/Hong Kong/1968(H3N2) y otra parte de A/Michigan/45/2015(H1N1)
- Se generó una secuencia adicional 'A/Test2/?/201?(H1N2)' combinando fragmentos de A/Swine/Indiana/P12439/00(H1N2) y A/Perth/16/2009(H3N2) que será utilizada específicamente para el análisis del segmento 4
- Para el segmento 4 (HA), que tiene un tamaño total de 1900 nucleótidos, la recombinación se diseñó de la siguiente manera:
 - A/Test/?/201?(H3N1):
 - Primeros 304 nucleótidos de A/Michigan/45/2015(H1N1)
 - Nucleótidos restantes de A/Hong Kong/1968(H3N2)
 - A/Test2/?/201?(H1N2):
 - Primeros 304 nucleótidos de A/Perth/16/2009(H3N2)
 - Nucleótidos restantes de A/Swine/Indiana/P12439/00(H1N2)

La selección de las secuencias base se realizó considerando los siguientes criterios:

- Para detectar eventos de transferencia horizontal entre dos parentales, se requiere un mínimo de cuatro secuencias: dos parentales, la secuencia recombinante/reordenada, y al menos una secuencia intermedia que comparta similitud genética con ambos parentales.
- Las secuencias intermedias seleccionadas son cruciales para la formación de la estructura topológica que caracteriza el evento de transferencia horizontal.
- Se seleccionaron específicamente:
 - A/Michigan/45/2015(H1N1) y A/Hong Kong/1968(H3N2) como secuencias parentales
 - A/Swine/Indiana/P12439/00(H1N2) como intermedio entre A/Michigan/45/2015(H1N1) y A/Perth/16/2009(H3N2)
 - A/Perth/16/2009(H3N2) como intermedio entre A/Hong Kong/1968(H3N2) y A/Swine/Indiana/P12439/00(H1N2)

4.1.3.4. Experimentos de control negativo

Para validar la especificidad del método de análisis topológico, se realizaron tres tipos de controles negativos, cada uno diseñado para evaluar diferentes aspectos del método:

a) Comparación entre Influenza A e Influenza B

Se diseñaron dos experimentos comparativos entre virus de influenza A y B

para evaluar la capacidad del método para distinguir entre grupos virales evolutivamente distantes:

- **Primer conjunto:** 30 secuencias de cada tipo (A y B)
 - Influenza A:
 - Marco temporal: 2004-2010
 - Diversidad de subtipos: H1N1, H3N2
 - Distribución geográfica: China con muestras adicionales de Estados Unidos y España
 - Influenza B:
 - Marco temporal: 2009-2010
 - Distribución geográfica: principalmente EE.UU., con algunas muestras de Sydney, Wuhan y Hong Kong
- **Segundo conjunto:** 50 secuencias de cada tipo
 - Influenza A:
 - Marco temporal: 2004-2010
 - Diversidad de subtipos: H1N1, H3N2
 - Mayor diversidad geográfica:
 - ◇ Asia: Shanghai, Vietnam, Singapur
 - ◇ Europa: Parma, Tomsk, Finlandia, Atenas, Madrid
 - ◇ América: Estados Unidos, México, Ontario
 - Influenza B:
 - Marco temporal: 2008-2010
 - Mayor diversidad geográfica:
 - ◇ Oceanía: Brisbane, Sydney, Townsville
 - ◇ Asia: Hong Kong, Wuhan, Bangladesh, Hubei
 - ◇ América: Nueva York, Wisconsin, Managua

b) Análisis de cepas cercanas

Se realizó un análisis utilizando conjuntos de secuencias del subtipo H1N1 que circularon en Norteamérica durante 2009-2010, con cuatro experimentos de diferente tamaño muestral:

- **Conjunto de 100 secuencias**
 - Distribución geográfica:
 - Estados Unidos (California, Nueva York, Texas, Wisconsin, entre otros)
 - Canadá (Columbia Británica y Manitoba)
 - México
 - Diversidad de hospedadores:
 - Principalmente humanos (85 % de las secuencias)
 - Cerdos (6 secuencias de México)

- Aves (1 secuencia de ánade real de Maryland)
 - Marco temporal: 2009-2010, con predominancia de muestras de 2009
 - **Conjunto de 60 secuencias** Subconjunto seleccionado del grupo anterior, manteniendo la representatividad geográfica y de hospedadores:
 - Todas las secuencias de México y Canadá
 - Selección equilibrada de muestras de diferentes estados de EE.UU.
 - Conservación de la diversidad de hospedadores
 - **Conjunto de 20 secuencias** Selección más reducida enfocada en muestras humanas de EE.UU.:
 - Distribución entre California, Nueva York, Texas y Wisconsin
 - Exclusivamente muestras de origen humano
 - **Conjunto de 7 secuencias** Análisis específico de las secuencias involucradas en los agujeros topológicos detectados en el conjunto de 60 secuencias, las secuencias utilizadas fueron las siguientes:
 - 1) A/Nebraska/23/2009(H1N1)
 - 2) A/California/VRDL121/2009(H1N1)
 - 3) A/California/VRDL133/2009(H1N1)
 - 4) A/New York/7236/2009(H1N1)
 - 5) A/New York/0461/2009(H1N1)
 - 6) A/Wisconsin/629-D01038/2009(H1N1)
 - 7) A/Wisconsin/629-D00459/2009(H1N1)
- c) **Análisis de cepas distantes**
- Se seleccionó un conjunto diverso de 37 secuencias de Influenza A, que abarca diferentes hospedadores, subtipos y períodos temporales:
- **Cepas aviarias:**
 - 8 secuencias H9N2 de pollos de Liaoning (China), 2015-2016
 - 1 secuencia H5N2 de pollo de Jalisco (México), 2020
 - 1 secuencia H7N3 de pollo de Puebla (México), 2019
 - **Cepas caninas:**
 - 2 secuencias H3N8 de Estados Unidos (Nueva York y Pensilvania), 2010
 - 8 secuencias H3N2 de Beijing (China), 2009
 - 1 secuencia H1N1 de Beijing (China), 2009
 - 1 secuencia H3N2 de Jiangsu (China), 2009
 - **Cepas equinas:**
 - 2 secuencias H7N7 (Detroit 1964, Lexington 1966)
 - 4 secuencias H3N8 de diferentes ubicaciones (São Paulo, Uruguay, Miami), 1963-1969
 - **Cepas porcinas:**

- 1 secuencia H3N2 de España, 2010
- 3 secuencias H1N1 de China (Jangsu y Yunnan), 2010
- 2 secuencias H1N1 de Corea, 2010
- 2 secuencias H1N1 de Tailandia, 2010
- 2 secuencias de México (H3N2 y H1N1), 2010

▪ **Cepa de mamífero marino:**

- 1 secuencia H13N2 de ballena (Maine), 1984

d) **Experimentos con secuencias artificiales**

Se realizó un conjunto de experimentos utilizando tanto secuencias naturales como artificialmente generadas, con el objetivo de evaluar la robustez del método de detección de transferencia horizontal. El conjunto de datos incluyó:

▪ **Secuencias naturales base:**

- **Subtipo H9N2** (24 secuencias):
 - Principalmente de origen aviar (pollos, patos, codornices)
 - Distribución geográfica: China (diversas provincias), Líbano, Hong Kong
 - Marco temporal: 2004-2017
- **Subtipo H7N9** (20 secuencias):
 - Origen mixto: aves domésticas, aves silvestres y humanos
 - Distribución geográfica: China (múltiples provincias) y Corea
 - Marco temporal: 2011-2013
- **Subtipo H7N3** (17 secuencias):
 - Principalmente de origen aviar
 - Distribución geográfica: China, Georgia, Corea, México, Canadá
 - Marco temporal: 2004-2013

▪ **Secuencias artificiales:**

Se generaron variantes artificiales de las seis secuencias clave involucradas en el agujero bidimensional detectado previamente:

- A/brambling/Beijing/16/2012(H9N2)
- A/quail/Wuxi/7/2010(H9N2)
- A/quail/Lebanon/273/2010(H9N2)
- A/Shanghai/02/2013(H7N9)
- A/wild bird/Korea/A14/2011(H7N9)
- A/duck/Zhejiang/10/2011(H7N3)

Para cada secuencia clave se generaron 5 variantes artificiales utilizando un algoritmo de mutación controlada. Este algoritmo se caracterizó por un proceso de mutación en el cual se seleccionaron aleatoriamente entre 1 y 4 segmentos por cada variante. Dentro de estos segmentos seleccionados, se introdujeron mutaciones puntuales aleatorias en los nucleótidos

de las secuencias. Para evaluar el efecto de diferentes tasas de mutación, se consideraron dos valores: una tasa de mutación del 0.02 (2 %) y otra del 0.1 (10 %).

A cada variante artificial se le nombró modificando el nombre original de la secuencia de la cual se tomó y agregando un identificador numérico, por ejemplo: A/wild_birdv1/Korea/A14/2011(H7N9)_variant_4.

4.1.3.5. Experimento de detección de recombinación en SARS-CoV-2

Para detectar eventos de recombinación en el virus SARS-CoV-2, se seleccionaron diez secuencias de variantes que circularon en México durante 2022-2023, distribuidas de la siguiente manera:

- **Variante BA.2** (3 secuencias):
 - Marco temporal: 2022
 - Distribución geográfica: Baja California Norte, Ciudad de México y Sinaloa
 - Secuencias:
 - ◇ hCoV-19/Mexico/BCN_CIAD-IMSS_202201050913/2022
 - ◇ hCoV-19/Mexico/MEX_InDRE_FB13911_E.S13150/2022
 - ◇ hCoV-19/Mexico/SIN_CIAD-MZT_HJ6105/2022
- **Variante BA.2.75.2** (3 secuencias):
 - Marco temporal: 2022
 - Distribución geográfica: Ciudad de México y Estado de México
 - Secuencias:
 - ◇ hCoV-19/Mexico/CMX_IBT_IMSS_9908/2022
 - ◇ hCoV-19/Mexico/MEX-INMEGEN-92x-18/2022
 - ◇ hCoV-19/Mexico/CMX-INMEGEN-95-310/2022
- **Variante XBB.1** (3 secuencias):
 - Marco temporal: 2022-2023
 - Distribución geográfica: Tamaulipas y Veracruz
 - Secuencias:
 - ◇ hCoV-19/Mexico/TAM_LANGEBIO_IMSS_13849/2022
 - ◇ hCoV-19/Mexico/TAM_LANGEBIO_IMSS_13854/2022
 - ◇ hCoV-19/Mexico/VER-LANGEBIO_IMSS_13979/2023
- **Variante BA.2.10.1** (2 secuencia):
 - Marco temporal: 2022-2023
 - Distribución geográfica: Querétaro, Hidalgo
 - Secuencia:

◊ hCoV-19/Mexico/QUE-LANGEBIO_IMSS_14092/2023

◊ hCoV-19/Mexico/HID-INMEGEN-70-132/2022

La selección de secuencias se realizó considerando la representatividad geográfica dentro de México y la inclusión estratégica de la variante XBB.1, conocida por ser producto de recombinación (4)

Las secuencias específicas utilizadas en cada experimento se detallan en el Apéndice C. Estos controles negativos fueron fundamentales para establecer la línea base del método y determinar su capacidad para discriminar entre eventos genuinos de transferencia genética horizontal y variación genética normal.

4.2. Implementación del TDA

4.2.1. Construcción de matrices de distancia

La implementación del Análisis Topológico de Datos (TDA) comenzó con la construcción de matrices de distancia a partir de las secuencias genómicas seleccionadas. Este paso es fundamental ya que transforma la información biológica en una estructura matemática que puede ser analizada mediante técnicas topológicas.

4.2.1.1. Cálculo de distancias

Para cuantificar la diferencia entre pares de secuencias, se utilizó la distancia de Hamming, cuando nos encontrábamos con gaps (representados por '-' en el alineamiento) o con nucleótidos ambiguos (representados como 'N' en las secuencias), no considerábamos una diferencia en el cálculo de la distancia.

4.2.1.2. Construcción de la matriz

Una vez calculadas las distancias entre todos los pares de secuencias, se construyó una matriz de distancia D la cual cumple las siguientes propiedades:

- **Simetría:** $D_{ij} = D_{ji}$ para todo i, j
- **Diagonal nula:** $D_{ii} = 0$ para todo i
- **No negatividad:** $D_{ij} \geq 0$ para todo i, j

La matriz resultante D tiene dimensiones $n \times n$, donde n es el número total de secuencias en el conjunto de datos. Esta matriz sirve como entrada para los siguientes pasos del análisis topológico, particularmente para la construcción de complejos simpliciales y el cálculo de la homología persistente.

4.2.2. Cálculo de homología persistente

4.2.2.1. Construcción del complejo simplicial

A partir de la matriz de distancia construida en la sección anterior, se generó una secuencia de complejos simpliciales mediante el algoritmo de Vietoris-Rips. Este proceso se realizó utilizando la biblioteca de software especializado GUDHI (Geometry Understanding in Higher Dimensions) (29)

4.2.3. Visualización de resultados

La visualización de los resultados del análisis topológico se implementó mediante múltiples representaciones complementarias, cada una diseñada para destacar diferentes aspectos de los datos y facilitar su interpretación:

4.2.3.1. Diagramas de persistencia

Se implementaron diagramas de persistencia utilizando las bibliotecas matplotlib y seaborn en Python, con las siguientes características:

- Ejes: nacimiento (x) vs muerte (y) de características topológicas
- Codificación por color según los objetos encontrados:
 - Rojo: componentes conectados (H_0)
 - Azul: agujeros unidimensionales (H_1)
 - Verde: agujeros bidimensionales (H_2)
- Línea diagonal: $y = x$ como referencia para la persistencia
- Escala adaptativa: ajustada automáticamente según el rango de los datos

4.2.3.2. Códigos de barras

Se generaron códigos de barras (barcodes) como representación alternativa de la persistencia, donde:

- Eje horizontal: valores del parámetro de filtración ϵ
- Eje vertical: características topológicas individuales
- Longitud de las barras: persistencia de cada característica
- Codificación por color según la dimensión homológica:
 - Rojo: componentes conectados (H_0)
 - Azul: agujeros unidimensionales (H_1)
 - Verde: agujeros bidimensionales (H_2)

4.2.3.3. Mapas de calor

Se implementaron mapas de calor para proporcionar una representación visual intuitiva de las relaciones entre las secuencias analizadas. Estos mapas permiten visualizar fácilmente patrones de similitud y diferencia entre pares de secuencias. Se utilizaron las siguientes convenciones:

- Estructura: matriz simétrica donde cada celda (i, j) representa la distancia entre las secuencias i y j
- Intensidad del color: proporcional a la distancia entre pares de secuencias, donde los colores más oscuros indican mayor similitud (menor distancia) mientras que los colores más claros indican menor similitud (mayor distancia).
- Escala de color: gradiente que va desde negro (distancias menores), luego pasa por rojo/naranja (distancias intermedias) y finaliza en blanco (distancias mayores)
- Diagonal principal: siempre de color negro, representando la comparación de cada secuencia consigo misma (distancia = 0)

Esta visualización resultó especialmente útil para:

- Identificar grupos de secuencias altamente similares
- Detectar patrones de divergencia que podrían indicar eventos de transferencia genética
- Validar visualmente los resultados obtenidos mediante el análisis de homología persistente
- Proporcionar una perspectiva complementaria a los diagramas de persistencia y códigos de barras

4.2.3.4. Visualización de complejos simpliciales

Para facilitar la interpretación de los resultados del análisis topológico de datos, se desarrollaron múltiples tipos de visualizaciones complementarias de los complejos simpliciales:

- **Visualización interactiva 3D:** Se implementó una visualización tridimensional interactiva exclusiva del experimento de validación de reordenamiento en H7N9 con las siguientes características:
 - Controles para modificar el valor de filtración mediante una barra deslizante
 - Entrada numérica directa del valor de filtración

- Rotación y zoom del modelo 3D
- Representación de:
 - Nodos (0-simplejos) con colores por cepa viral
 - Aristas (1-simplejos) como líneas entre nodos
 - Triángulos (2-simplejos) como superficies semitransparentes rojas
 - Tetraedros (3-simplejos) como volúmenes semitransparentes verdes
 - Resaltado en amarillo de los simplejos que cierran agujeros topológicos
- **Visualización simplificada:** Se desarrolló una versión estática más simple con las siguientes características:
 - Mantiene las mismas convenciones visuales que la versión interactiva
 - Muestra un único valor de filtración a la vez
 - Requiere menos recursos computacionales

4.2.3.5. Herramientas y bibliotecas utilizadas

La implementación se realizó utilizando las siguientes herramientas y bibliotecas de Python:

- Python como lenguaje principal de programación
- Bibliotecas de visualización:
 - Matplotlib y Seaborn para la generación de gráficos estadísticos básicos, incluyendo mapas de calor y diagramas de persistencia
 - Plotly para la creación de visualizaciones interactivas tridimensionales de complejos simpliciales
- Bibliotecas para análisis topológico:
 - GUDHI para:
 - Construcción de complejos de Rips
 - Cálculo de homología persistente
 - Generación de diagramas de persistencia y códigos de barras
 - NetworkX para:
 - Manipulación y visualización de grafos
 - Representación de estructuras simpliciales
 - Generación de layouts para visualizaciones 3D
- Bibliotecas complementarias:
 - NumPy para operaciones con matrices y cálculos numéricos
 - ipywidgets para la creación de interfaces interactivas con controles deslizantes y campos de entrada

Resultados

En este capítulo se presentan los resultados obtenidos tras aplicar el método de análisis topológico para la detección de eventos de transferencia genética horizontal en virus. La presentación de resultados se organiza en tres secciones principales: primero, se muestran los resultados de los experimentos de control negativo; segundo, se presentan las pruebas de robustez que evalúan el comportamiento del método bajo diferentes condiciones; y tercero, se analizan los resultados de los casos de estudio específicos del reordenamiento triple en H7N9 y la recombinación en SARS-CoV-2.

5.1. Resultados de controles negativos

Para evaluar el desempeño del método de análisis topológico, se realizaron diversos experimentos de control negativo. Esta sección presenta los resultados obtenidos en cada uno de ellos, organizados según el tipo de comparación y análisis realizado.


5.1.1. Comparación entre Influenza A e Influenza B

Se analizaron dos conjuntos de datos: uno con 30 secuencias y otro con 50 secuencias de cada tipo viral. La aplicación de homología persistente reveló en ambos casos que no se detectaron agujeros topológicos, lo cual era esperado dado que no hay evidencia de transferencia genética horizontal entre cepas del mismo tipo viral en estos conjuntos. Adicionalmente, se observó una clara separación en el espacio topológico, manifestada por valores elevados de H_0 (componentes conectados) que persistieron durante rangos amplios de la filtración. Este resultado era esperado dado que la Influenza A y la Influenza B son virus evolutivamente distantes, con diferencias genéticas significativas que se reflejan en el análisis topológico como una marcada separación espacial entre los puntos que representan

5. RESULTADOS

sus secuencias. Esta distancia topológica requiere valores de filtración considerablemente altos antes de que las componentes se conecten, lo cual es consistente con la divergencia evolutiva conocida entre estos dos tipos virales.

30 secuencias por tipo viral



50 secuencias por tipo viral




Figura 5.1: La homología persistente demuestra la ausencia de transferencia genética horizontal entre virus de Influenza A e Influenza B. Los diagramas de persistencia (izquierda) y códigos de barras (derecha) revelan únicamente componentes conectados (H_0) para ambos tipos virales. Las secuencias de Influenza A corresponden a subtipos H1N1 y H3N2 aislados de humanos en China, Estados Unidos y España (2004-2010), mientras que las de Influenza B provienen de aislados humanos de Estados Unidos, Asia y Oceanía (2008-2010).

5.1.2. Análisis de cepas cercanas de H1N1

Se realizó un análisis progresivo reduciendo el tamaño muestral empezando por 100, luego 60, 20 y finalmente 7 secuencias de H1N1, todas provenientes de Estados Unidos en el lapso de diciembre de 2009. Los resultados obtenidos fueron los siguientes:

Para el conjunto de 100 secuencias, el análisis topológico reveló la presencia de un agujero de dimensión 1 (H1) con baja persistencia (nacimiento en $\epsilon = 36.0$ y muerte en $\epsilon = 37.0$). Este agujero está formado por las siguientes secuencias (se indica la fecha de colección entre paréntesis):

- A/Wisconsin/629-D00636/2009(H1N1) (10 de diciembre de 2009)
- A/New York/7421/2009(H1N1) (6 de diciembre de 2009)
- A/California/VRDL128/2009(H1N1) (22 de diciembre de 2009)
- A/Texas/JMS392/2009(H1N1) (25 de diciembre de 2009)

Al reducir el conjunto a 60 secuencias, se observó la presencia de dos agujeros de dimensión 1 (H1) con baja persistencia. El primer agujero aparece en $\epsilon = 40.0$ y desaparece en $\epsilon = 41.0$, formado por las siguientes secuencias:

- A/Nebraska/23/2009(H1N1) (30 de diciembre de 2009)
- A/New York/0461/2009(H1N1) (30 de diciembre de 2009)
- A/Wisconsin/629-D01038/2009(H1N1) (18 de diciembre de 2009)
- A/California/VRDL133/2009(H1N1) (30 de diciembre de 2009)

El segundo agujero surge en $\epsilon = 45.0$ y desaparece en $\epsilon = 46.0$, involucrando las siguientes secuencias:

- A/California/VRDL121/2009(H1N1) (15 de diciembre de 2009)
- A/Wisconsin/629-D00459/2009(H1N1) (18 de diciembre de 2009)
- A/New York/7236/2009(H1N1) (28 de diciembre de 2009)
- A/California/VRDL133/2009(H1N1) (30 de diciembre de 2009)

5. RESULTADOS




Figura 5.2: Visualización tridimensional de los dos agujeros topológicos detectados en el conjunto de 60 secuencias. A la izquierda se muestra el primer ciclo H1 (nacimiento: 40.0, muerte: 41.0) y a la derecha el segundo ciclo H1 (nacimiento: 45.0, muerte: 46.0).

En el conjunto de 20 secuencias, se encontró un único agujero H1 que nace en $\epsilon = 45.0$ y muere en $\epsilon = 46.0$. Este agujero está formado por las mismas secuencias que conforman el segundo agujero del conjunto de 60:

- A/California/VRDL121/2009(H1N1) (15 de diciembre de 2009)
- A/Wisconsin/629-D00459/2009(H1N1) (18 de diciembre de 2009)
- A/New York/7236/2009(H1N1) (28 de diciembre de 2009)
- A/California/VRDL133/2009(H1N1) (30 de diciembre de 2009)




Figura 5.3: Visualización del agujero topológico para el conjunto de 20 secuencias.

Finalmente, al analizar específicamente las 7 secuencias involucradas en los agujeros topológicos detectados en el conjunto de 60 secuencias, pudimos confirmar la presencia del agujero H1 con idéntico tiempo de vida (ϵ de nacimiento = 45.0, ϵ de muerte = 46.0). Este agujero está formado por las mismas cuatro secuencias identificadas previamente.

5. RESULTADOS




Figura 5.4: Visualización tridimensional del agujero topológico para el conjunto de 7 secuencias.




Figura 5.5: Los diagramas de persistencia (izquierda) y códigos de barras (derecha) muestran los resultados para conjuntos de 100, 60, 20 y 7 secuencias de H1N1.



Es importante resaltar que a lo largo de este análisis progresivo se observó un fenómeno interesante: el agujero encontrado en el conjunto más grande de 100 secuencias ($\epsilon = 36.0 - 37.0$) es completamente diferente de los agujeros detectados

en los conjuntos más pequeños, tanto en las secuencias involucradas como en los valores de ϵ donde aparece. Mientras que los conjuntos de 60, 20 y 7 secuencias mantienen consistencia en al menos uno de sus agujeros topológicos (específicamente el que aparece en $\epsilon = 45.0 - 46.0$), el conjunto de 100 secuencias revela un agujero totalmente distinto. Esta observación nos permite concluir que los agujeros topológicos no necesariamente se preservan al aumentar el tamaño del conjunto de datos. De hecho, la adición de más secuencias puede resultar en la aparición de nuevos agujeros topológicos o en la desaparición de otros previamente detectados. Esto indica que los resultados del método dependen fuertemente de qué secuencias específicas se incluyen en el análisis y cómo estas se relacionan entre sí, más que del tamaño total del conjunto de datos.

5.1.3. Análisis de cepas distantes

En el análisis del conjunto diverso de 37 secuencias de Influenza A, que abarcó diferentes hospedadores (aves, cerdos, perros, caballos y una ballena), subtipos y períodos temporales, el análisis topológico reveló los siguientes resultados:

- Se detectó un único agujero unidimensional (H1) que nace en $\epsilon = 492$ y muere en $\epsilon = 501$.
- Este agujero involucraba exclusivamente las siguientes secuencias de H9N2 provenientes de pollos de la provincia de Liaoning, China, del período 2015-2016:
 - A/chicken/Liaoning/12/2016(H9N2)
 - A/chicken/Liaoning/13/2016(H9N2)
 - A/chicken/Liaoning/04/2015(H9N2)
 - A/chicken/Liaoning/08/2015(H9N2)
- No se encontraron agujeros topológicos que involucraran secuencias de diferentes subtipos o de diferentes especies hospedadoras.



dado que estas secuencias provienen de la misma especie hospedadora y el mismo subtipo viral en una región geográfica y período temporal acotados. Sin embargo, lo más relevante de este experimento es la ausencia de agujeros topológicos que involucren secuencias de diferentes especies hospedadoras o diferentes subtipos virales, lo cual es consistente con las restricciones biológicas conocidas para la transferencia genética horizontal en virus de influenza.

5.2. Validación de reordenamiento en H7N9

5.2.1. Análisis de segmentos concatenados

Los resultados obtenidos al aplicar homología persistente al conjunto de secuencias concatenadas revelaron evidencia significativa de un evento de reordenamiento triple en el virus H7N9. El análisis topológico identificó las siguientes características:

- Un agujero unidimensional (H1) que nace en $\epsilon = 1673$ y muere en $\epsilon = 2026$
- Un agujero bidimensional (H2) que nace en $\epsilon = 2027$ y muere en $\epsilon = 2080$




Figura 5.8: A la izquierda, diagrama de persistencia del análisis de secuencias concatenadas de H7N9. A la derecha, código de barras correspondiente. Se observa el agujero unidimensional (H1) y el agujero bidimensional (H2).

La presencia del agujero bidimensional es relevante, ya que indica un evento de reordenamiento que involucra tres secuencias parentales diferentes. Por otro lado, el agujero unidimensional detectado, con una persistencia significativa de 353 unidades de filtración, podría indicar un evento de reordenamiento intermedio en la evolución de estas cepas virales.




Figura 5.9: Mapa de calor mostrando las distancias genéticas entre las secuencias analizadas.

El mapa de calor de las distancias genéticas (Figura 5.9) muestra patrones distintivos de similitud entre las secuencias. Al observar el renglón de la secuencia A/Shanghai/02/2013(H7N9), podemos notar dos cuadros de color anaranjado, lo cual representa una lejanía filogenética con respecto a las demás secuencias. Esto podría ser un indicio de que las secuencias A/brambling/Beijing/16/2012(H9N2) y A/wild bird/Korea/A14/2011(H7N9) están implicadas en el reordenamiento triple que formó a la secuencia A/Shanghai/02/2013(H7N9).

5. RESULTADOS




Figura 5.10: Visualización tridimensional del complejo simplicial en $\epsilon = 2027$, donde se observa la formación del agujero bidimensional que caracteriza el reordenamiento triple. El simplejo que se forma en ese momento y por el que obtenemos nuestro agujero bidimensional está coloreado de amarillo.

Mediante la visualización tridimensional implementada (Figura 5.10), fue posible observar la formación y evolución de las estructuras topológicas que caracterizan el reordenamiento triple. Esta herramienta permitió confirmar visualmente la presencia del agujero bidimensional y su relación con las diferentes cepas virales involucradas. Estos resultados pueden compararse con los obtenidos en los artículos “Human Infection with a Novel Avian-Origin Influenza A (H7N9) Virus” (12) y “Sequential Reassortments Underlie Diverse Influenza H7N9 Genotypes in China” (40), donde utilizaron otras técnicas para lograr encontrar los genes relacionados a la cepa H7N9 y llegaron a resultados similares a los nuestros. En el artículo de Gao et al., los autores realizaron un análisis filogenético de los genes de las cepas A/Shanghai/1/2013, A/Shanghai/2/2013 y A/Anhui/1/2013. Encontraron que el gen de la neuraminidasa (NA) estaba más cercano a A/wild bird/Korea/A14/2011(H7N9). Además, los seis genes internos compartían la mayor similitud con el virus A/brambling/Beijing/16/2012-like(H9N2). (12)

5.2.1.1. Análisis de segmentos individuales




Figura 5.11: Diagramas de persistencia individuales para cada uno de los ocho segmentos genómicos analizados. Se observa la ausencia de agujeros en todos los segmentos cuando se analizan de manera individual.

Adicionalmente, se aplicó homología persistente de manera individual a cada uno de los ocho segmentos genómicos de las secuencias virales. Los resultados revelaron que ninguno de los segmentos mostró agujeros en sus diagramas de persistencia (Figura 5.11). Esta observación contrasta con los resultados obtenidos del análisis del genoma concatenado, donde sí se detectaron agujeros de dimensión 1 y 2.

La diferencia entre los resultados del análisis por segmentos y el análisis del genoma completo es notoria: mientras que el análisis del genoma concatenado reveló estructuras topológicas complejas (H1 y H2), el análisis individual de cada segmento solo mostró características topológicas de dimensión 0. Esta distinción en los resultados sugiere una diferencia fundamental en la estructura topológica entre los segmentos individuales y el genoma completo.

5.3. Recombinación en SARS-CoV-2

5.3.1. Análisis de secuencias concatenadas

Al aplicar homología persistente al conjunto de secuencias concatenadas del virus SARS-CoV-2, se obtuvieron resultados que sugieren la presencia de eventos de recombinación. El análisis topológico reveló las siguientes características:

Se detectó un agujero unidimensional (H1) que nació en $\epsilon = 58$ y murió en $\epsilon = 74$. Este agujero está formado por las siguientes secuencias:

- hCoV-19/Mexico/CMX_IBT_IMSS_9908/2022 (BA.2.75.2)
- hCoV-19/Mexico/MEX-INMEGEN-92x-18/2022 (BA.2.75.2)
- hCoV-19/Mexico/QUE-LANGEBIO_IMSS_14092/2023 (BA.2.10.1)
- hCoV-19/Mexico/SIN_CIAD-MZT_HJ6105/2022 (BA.2)

La presencia del agujero unidimensional sugiere un evento de recombinación que involucra múltiples variantes virales, incluyendo linajes BA.2, BA.2.75.2 y BA.2.10.1.




Figura 5.12: Diagramas de persistencia y códigos de barras para el análisis del SARS-CoV-2, mostrando el agujero unidimensional detectado.

5.3.1.1. Análisis de segmentos individuales

Para obtener una comprensión más detallada de la recombinación en el SARS-CoV-2, se segmentó el genoma de cada muestra según las diferentes proteínas virales. Al aplicar homología persistente a cada segmento por separado, los resultados mostraron que únicamente la proteína Spike (S) presentó un agujero unidimensional (H1), lo cual sugiere que los eventos de recombinación ocurrieron específicamente en esta región del genoma.

El análisis específico de cada proteína, reveló que la proteína Spike (S) fue la única que mostró evidencia de recombinación al presentar un agujero unidimensional en su diagrama de persistencia.

Además, se obtuvo el mapa de calor de la matriz de distancia de cada uno de los segmentos, permitiéndonos visualizar algunos datos interesantes. Podemos observar que las proteínas M, ORF7a y ORF7b son idénticas en todas nuestras muestras. Por otro lado, ORF6 solo difiere en la muestra BA.2.10.1 hCoV-19/Mexico/QUE-LANGEBIO IM

5. RESULTADOS




Figura 5.13: Diagramas de persistencia individuales para cada uno de los segmentos que codifican proteínas en el virus SARS-CoV-2. Se observa la presencia de un agujero unidimensional únicamente en el diagrama correspondiente a la proteína Spike (S).




Figura 5.14: Mapas de calor individuales para cada una de las proteínas del SARS-CoV-2

5.4. Resultados de pruebas de robustez

5.4.1. Análisis de sensibilidad al tamaño muestral

Con el objetivo de evaluar si la señal topológica del reordenamiento triple (caracterizada por el agujero bidimensional) se mantiene al aumentar el tamaño de la muestra, se realizaron análisis con conjuntos de datos progresivamente más grandes. El primer conjunto, compuesto por 21 secuencias (las 6 secuencias originales del experimento de validación más 5 secuencias adicionales de origen aviar por cada uno de los subtipos H9N2, H7N9 y H7N3), reveló la persistencia del agujero bidimensional (H2) con coordenadas de nacimiento en $\epsilon = 1996.0$ y muerte en $\epsilon = 2011.0$. Adicionalmente, se detectaron tres agujeros unidimensionales (H1) con los siguientes intervalos de persistencia:

- H1₁: nacimiento en $\epsilon = 1316.0$, muerte en $\epsilon = 1360.0$
- H1₂: nacimiento en $\epsilon = 1624.0$, muerte en $\epsilon = 1642.0$
- H1₃: nacimiento en $\epsilon = 1614.0$, muerte en $\epsilon = 1956.0$

Para el conjunto de 27 secuencias (5 aviares + 2 humanas por subtipo), en el cual se agregaron tanto secuencias de origen aviar como humano, se mantuvo la señal del reordenamiento triple. El agujero bidimensional (H2) apareció en $\epsilon = 1970.0$ y desapareció en $\epsilon = 2027.0$. El análisis también reveló cuatro agujeros unidimensionales (H1) con los siguientes intervalos de persistencia:

- H1₁: nacimiento en $\epsilon = 1303.0$, muerte en $\epsilon = 1326.0$
- H1₂: nacimiento en $\epsilon = 1270.0$, muerte en $\epsilon = 1381.0$
- H1₃: nacimiento en $\epsilon = 1488.0$, muerte en $\epsilon = 1493.0$
- H1₄: nacimiento en $\epsilon = 1598.0$, muerte en $\epsilon = 1928.0$


Para el conjunto de 39 secuencias (8 aviares + 3 humanas por cada subtipo), el análisis reveló un cambio significativo en la estructura topológica: el agujero bidimensional (H2) característico del reordenamiento triple dejó de ser detectable. Sin embargo, se identificaron cuatro agujeros unidimensionales (H1) con los siguientes intervalos de persistencia:

- H1₁: nacimiento en $\epsilon = 1268.0$, muerte en $\epsilon = 1287.0$
- H1₂: nacimiento en $\epsilon = 1291.0$, muerte en $\epsilon = 1331.0$
- H1₃: nacimiento en $\epsilon = 1474.0$, muerte en $\epsilon = 1491.0$
- H1₄: nacimiento en $\epsilon = 1587.0$, muerte en $\epsilon = 1914.0$


Finalmente, en el análisis del conjunto más grande, compuesto por 54 secuencias (13 aviares + 5 humanas por cada subtipo), se confirmó la pérdida de la señal del

reordenamiento triple, ya que el agujero bidimensional (H2) permaneció ausente. En este caso, solo se detectó un agujero unidimensional (H1) con un intervalo de persistencia de nacimiento en $\epsilon = 1370.0$ y muerte en $\epsilon = 1567.0$. Estos resultados demuestran que la capacidad del método para detectar el reordenamiento triple a través del agujero bidimensional (H2) se mantiene robusta hasta cierto tamaño muestral. Específicamente, la señal topológica persiste al aumentar el conjunto a 21 y 27 secuencias, pero desaparece cuando el tamaño de la muestra alcanza las 39 secuencias. Esta pérdida de la señal sugiere que existe un umbral en el tamaño muestral, aproximadamente entre 27 y 39 secuencias, más allá del cual la complejidad adicional del espacio topológico puede enmascarar la estructura característica del reordenamiento triple. Es importante notar que mientras el agujero bidimensional desaparece, los agujeros unidimensionales (H1) persisten incluso en conjuntos más grandes, aunque su número y características específicas varían con el tamaño de la muestra.


21 secuencias



27 secuencias



39 secuencias



54 secuencias




Figura 5.15: Análisis de sensibilidad al tamaño muestral. Se muestran los diagramas de persistencia (izquierda) y códigos de barras (derecha) para los distintos conjuntos de datos. La señal del agujero bidimensional (H2) característico del reordenamiento triple se mantiene visible en los conjuntos de 21 y 27 secuencias, pero desaparece en los conjuntos más grandes de 39 y 54 secuencias

5.4.2. Análisis con secuencias artificiales complementarias

Se planteó la hipótesis de que la pérdida de señal topológica observada en conjuntos grandes de datos podría contrarrestarse mediante el uso de secuencias artificiales diseñadas específicamente para reforzar la detección del reordenamiento triple. Se partió de un conjunto base de 61 secuencias naturales (24 secuencias H9N2, 20 secuencias H7N9 y 17 secuencias H7N3) al cual se añadieron 30 secuencias artificiales.

Las variantes artificiales se generaron mediante un algoritmo de mutación controlada aplicado a cada una de las seis secuencias clave involucradas en el reordenamiento triple original:

- A/brambling/Beijing/16/2012(H9N2)
- A/quail/Wuxi/7/2010(H9N2)
- A/quail/Lebanon/273/2010(H9N2)
- A/Shanghai/02/2013(H7N9)
- A/wild_bird/Korea/A14/2011(H7N9)
- A/duck/Zhejiang/10/2011(H7N3)

Para cada secuencia clave se crearon 5 variantes utilizando el siguiente proceso:

- Se seleccionaron aleatoriamente entre 1 y 4 segmentos por cada variante
- En los segmentos seleccionados, se introdujeron mutaciones puntuales aleatorias en los nucleótidos
- Se aplicaron dos tasas diferentes de mutación para evaluar el efecto: 2 % y 10 %

Las variantes artificiales se nombraron modificando el nombre original de la secuencia y agregando un identificador numérico.

(por ejemplo: A/wild_birdv1/Korea/A14/2011(H7N9)_variant_4).

El experimento comenzó analizando el conjunto ampliado de 91 secuencias utilizando una tasa de mutación del 2 % para la generación de las variantes artificiales. El análisis topológico reveló dos agujeros unidimensionales (H1) con los siguientes intervalos de persistencia:

- H₁₁: nacimiento en $\epsilon = 1068.0$, muerte en $\epsilon = 1072.0$
- H₁₂: nacimiento en $\epsilon = 1371.0$, muerte en $\epsilon = 1565.0$

5. RESULTADOS




Figura 5.16: Visualizaciones del análisis topológico para el conjunto ampliado con secuencias artificiales (tasa de mutación 2 %). A la izquierda, diagrama de persistencia mostrando los dos agujeros unidimensionales (H_1). A la derecha, el código de barras correspondiente.

Para la segunda fase del experimento, se analizó el mismo conjunto utilizando variantes artificiales generadas con una tasa de mutación del 10 %. En este caso, el análisis topológico reveló una estructura más compleja, con siete agujeros unidimensionales (H_1):

- H_{1_1} : nacimiento en $\epsilon = 901.0$, muerte en $\epsilon = 956.0$
- H_{1_2} : nacimiento en $\epsilon = 1270.0$, muerte en $\epsilon = 1281.0$
- H_{1_3} : nacimiento en $\epsilon = 1264.0$, muerte en $\epsilon = 1305.0$
- H_{1_4} : nacimiento en $\epsilon = 1306.0$, muerte en $\epsilon = 1323.0$
- H_{1_5} : nacimiento en $\epsilon = 1308.0$, muerte en $\epsilon = 1334.0$
- H_{1_6} : nacimiento en $\epsilon = 1616.0$, muerte en $\epsilon = 1643.0$
- H_{1_7} : nacimiento en $\epsilon = 1371.0$, muerte en $\epsilon = 1905.0$




Figura 5.17: Visualizaciones del análisis topológico para el conjunto ampliado con secuencias artificiales (tasa de mutación 10 %). A la izquierda, diagrama de persistencia mostrando los siete agujeros unidimensionales (H_1). A la derecha, el código de barras correspondiente.

Los resultados de ambos experimentos, tanto con tasa de mutación del 2 % como del 10 %, revelan que la estrategia de añadir secuencias artificiales similares no logró preservar la detección del agujero bidimensional característico del reordenamiento triple. Por lo que se puede concluir que la pérdida de información en conjuntos grandes de datos no puede ser contrarrestado simplemente mediante la adición de secuencias artificiales similares.

5.5. Resultados de experimentos de simulación

5.5.1. Simulación control

Se analizó un conjunto de secuencias naturales sin modificaciones artificiales. Este experimento de control permitió establecer una base para la interpretación de los resultados posteriores.

El análisis topológico del conjunto control, compuesto por cinco secuencias de diferentes subtipos (H1N1, H1N2 y H3N2), no reveló la presencia de agujeros topológicos de ninguna dimensión. Como se puede observar en el diagrama de persistencia y el código de barras (Figura 5.18), solo se detectaron componentes conectados (H_0) que eventualmente se fusionan a medida que el parámetro de filtración aumenta, hasta formar una única componente conectada.

5. RESULTADOS




Figura 5.18: Visualizaciones del análisis topológico para la simulación control. A la izquierda, diagrama de persistencia mostrando únicamente componentes conectados (H_0). A la derecha, el código de barras correspondiente.

La visualización tridimensional del complejo simplicial en $\epsilon = 2126$ (Figura 5.19) muestra que para este valor de filtración todas las secuencias están conectadas entre sí mediante aristas, formando una única componente conexa sin estructuras topológicas adicionales. Este resultado es consistente con lo esperado para un conjunto de secuencias que no han experimentado eventos de transferencia genética horizontal.




Figura 5.19: Visualización tridimensional del complejo simplicial en $\epsilon = 2126$ para la simulación control. Se observa que todas las secuencias están conectadas mediante aristas (1-simplejos), formando una única componente conexa sin agujeros topológicos.

5. RESULTADOS




Figura 5.20: Diagramas de persistencia individuales para cada uno de los ocho segmentos genómicos analizados en la simulación control.

También, se aplicó homología persistente de manera individual a cada uno de los

ocho segmentos genómicos que componen el virus de influenza. Los diagramas de persistencia resultantes (Figura 5.20) muestran únicamente características topológicas de dimensión 0, sin evidencia de agujeros en ninguna dimensión. Este resultado es consistente con lo esperado en un conjunto de secuencias que no han experimentado eventos de transferencia horizontal.

5.5.2. Simulación de reordenamiento

5.5.2.1. Análisis de secuencias concatenadas

Para evaluar la capacidad del método para detectar eventos de reordenamiento, se analizó un conjunto que incluía una variante híbrida ('A/Test/?/201?(H3N1)') generada mediante la combinación del segmento 4 (HA) de A/Hong Kong/1968(H3N2) con los demás segmentos de A/Michigan/45/2015(H1N1). El análisis topológico reveló la presencia de un agujero unidimensional (H1):

- H1: nacimiento en $\epsilon = 2133.0$, muerte en $\epsilon = 2147.0$




Figura 5.21: Visualizaciones del análisis topológico para la simulación de reordenamiento. A la izquierda, diagrama de persistencia mostrando el agujero unidimensional (H1). A la derecha, el código de barras correspondiente.




Figura 5.22: Visualización tridimensional del complejo simplicial en $\epsilon = 2133.0$, donde se observa la formación del agujero unidimensional (H_1). Los vértices están coloreados según el subtipo viral: H1N1 en naranja, H3N2 en azul, H1N2 en verde y H3N1 en amarillo.

El agujero unidimensional detectado está formado específicamente por las siguientes secuencias:

- A/Test/?/201?(H3N1) - secuencia reordenada
- A/Hong Kong/1968(H3N2)
- A/Perth/16/2009(H3N2)
- A/Swine/Indiana/P12439/00(H1N2)

5.5.2.2. Análisis de segmentos individuales

Se realizó el análisis topológico de cada uno de los ocho segmentos genómicos por separado. A diferencia del análisis de secuencias concatenadas, donde se detectó un agujero unidimensional característico del evento de reordenamiento, el análisis individual de los segmentos no reveló agujeros topológicos en ninguna dimensión.

5.5 Resultados de experimentos de simulación




Figura 5.23: Diagramas de persistencia individuales para cada uno de los ocho segmentos genómicos analizados en la simulación de reordenamiento. Se observa la ausencia de agujeros en todos los segmentos cuando se analizan de manera individual, incluso en el segmento 4 (HA) que fue el utilizado para generar el reordenamiento.

5. RESULTADOS

Este resultado es importante ya que demuestra que la señal topológica del reordenamiento solo ocurre cuando se analiza el genoma completo de manera concatenada.

5.5.3. Simulación de recombinación

5.5.3.1. Análisis de secuencias concatenadas

Para evaluar la capacidad del método para detectar eventos de recombinación, se analizó un conjunto que incluía una variante artificial “A/Test/?/201?(H3N1)”, que contiene una región recombinante en el segmento 4 derivada de A/Hong Kong/1968(H3N2) y A/Michigan/45/2015(H1N1). El análisis topológico reveló la presencia de un agujero unidimensional (H1):

- H1: nacimiento en $\epsilon = 2126.0$, muerte en $\epsilon = 2147.0$




Figura 5.24: Visualizaciones del análisis topológico para la simulación de recombinación. A la izquierda, diagrama de persistencia mostrando el agujero unidimensional (H1). A la derecha, el código de barras correspondiente.




Figura 5.25: Visualización tridimensional del complejo simplicial en $\epsilon = 2126.0$, donde se observa la formación del agujero unidimensional (H1). El ciclo que forma es topológicamente idéntico al detectado en el experimento de reordenamiento.

Podemos notar que este agujero unidimensional está formado por las mismas secuencias que nos formaban nuestro ciclo en el experimento de reordenamiento:

- A/Test/?/201?(H3N1) - secuencia recombinante
- A/Hong Kong/1968(H3N2)
- A/Perth/16/2009(H3N2)
- A/Swine/Indiana/P12439/00(H1N2)

Este resultado sugiere que el método, al analizar secuencias concatenadas, no distingue entre eventos de reordenamiento y recombinación.

5.5.3.2. Análisis de segmentos individuales

Dado que los siete segmentos restantes son idénticos a los del experimento de reordenamiento, nos enfocamos exclusivamente en el análisis del segmento 4 (HA), donde se realizó la modificación para simular la recombinación. El análisis inicial del segmento 4 con la secuencia A/Test/?/201?(H3N1) reveló una estructura topológica distintiva, aunque sin agujeros detectables:

5. RESULTADOS




Figura 5.26: Diagramas de persistencia del segmento 4 para recombinación (izquierda) y reordenamiento (derecha).




Figura 5.27: Visualización de los complejos simpliciales en $\epsilon = 650$. En el caso de recombinación (izquierda) se observan dos grupos diferenciados: una arista aislada entre Michigan y Swine, y un prisma triangular formado por las secuencias restantes. En contraste, el reordenamiento (derecha) muestra una única estructura conectada formada por un triángulo (Test-Michigan-Swine) y un tetraedro (secuencias H3N2 y Test), unidos a través del vértice Test.

La diferencia estructural observada sugirió la necesidad de incluir una secuencia intermediaria adicional. Por ello, se incorporó A/Test2/?/201?(H1N2) al análisis,

lo que produjo resultados notablemente diferentes entre ambos tipos de transferencia horizontal:




Figura 5.28: Diagramas de persistencia del segmento 4 incluyendo A/-Test2/?/201?(H1N2). La recombinación (izquierda) muestra un agujero unidimensional característico, mientras que el reordenamiento (derecha) mantiene la ausencia de agujeros topológicos.

Esta distinción en las señales topológicas a nivel de segmento individual proporciona un criterio para diferenciar entre eventos de reordenamiento y recombinación: mientras que el reordenamiento solo es detectable al analizar el genoma completo, la recombinación muestra un agujero unidimensional tanto en el análisis del genoma completo como cuando se analiza específicamente el segmento donde ocurrió el evento, especialmente cuando se incluyen secuencias intermediarias adecuadas.




Figura 5.29: Visualización de los complejos simpliciales en $\epsilon = 650$ incluyendo A/-Test2/?/201?(H1N2). En el caso de recombinación (izquierda) se observa la formación de un agujero unidimensional formado por las secuencias A/Test2/?/201?(H1N2), A/-Test/?/201?(H3N1), A/Swine/Indiana/P12439/00(H1N2), A/Michigan/45/2015(H1N1), A/Hong Kong/1968(H3N2) y A/Perth/16/2009(H3N2). En contraste, el reordenamiento (derecha) mantiene una estructura sin agujeros topológicos.

Discusión

6.1. Análisis de la validación del método

6.1.1. Interpretación de los controles negativos

Los experimentos de control negativo se diseñaron estratégicamente para evaluar tres aspectos fundamentales del método:

- a)* La capacidad para distinguir entre tipos virales evolutivamente distantes: mediante la comparación entre secuencias de Influenza A e Influenza B
- b)* El comportamiento frente a conjuntos de secuencias cercanas evolutivamente: utilizando diferentes conjuntos de secuencias H1N1 del mismo período temporal y región geográfica
- c)* La respuesta ante grupos diversos de secuencias sin eventos conocidos de transferencia horizontal: analizando un conjunto heterogéneo que incluía secuencias de diferentes hospedadores, subtipos y períodos temporales

En el primer aspecto, la comparación entre virus de Influenza A e Influenza B proporcionó los resultados esperados. La ausencia total de agujeros topológicos en estos conjuntos de datos, tanto en el grupo de 30 como en el de 50 secuencias por tipo viral, demostró que el método no genera señales falsas positivas cuando analiza grupos claramente diferenciados evolutivamente.

Por otro lado, el análisis progresivo de cepas cercanas de H1N1 reveló un aspecto importante sobre la generación de falsos positivos en el método. En todos los conjuntos analizados (100, 60, 20 y 7 secuencias) se detectaron agujeros unidimensionales (H_1) con características que sugieren fuertemente que son falsos positivos:

- Persistencia extremadamente baja: en todos los casos, la diferencia entre el tiempo de nacimiento y muerte fue de solo una unidad (ϵ)
- Proximidad temporal extrema: todas las secuencias involucradas fueron recolectadas en un período muy corto (diciembre de 2009)
- Coherencia geográfica: las secuencias provenían de la misma región (Estados Unidos)

Por ejemplo, en el conjunto de 60 secuencias, se detectaron dos agujeros H_1 :

- Primer agujero: nacimiento en $\epsilon = 40.0$ y muerte en $\epsilon = 41.0$
- Segundo agujero: nacimiento en $\epsilon = 45.0$ y muerte en $\epsilon = 46.0$

La persistencia de solo una unidad en estos agujeros, combinada con el hecho de que las secuencias que los forman fueron recolectadas en un lapso de apenas dos semanas (del 15 al 30 de diciembre de 2009), hace extremadamente improbable que representen eventos genuinos de transferencia horizontal. Es más plausible que estas señales topológicas reflejen patrones de variación genética normal dentro de una población viral que evoluciona rápidamente en un área geográfica limitada. Este hallazgo es importante pues establece un criterio importante para la interpretación de resultados: los agujeros topológicos con persistencia extremadamente baja (diferencia de una unidad entre nacimiento y muerte) deben ser considerados con extrema precaución, especialmente cuando involucran secuencias con alta proximidad temporal y geográfica.

El análisis del conjunto diverso de 37 secuencias que abarcaba diferentes hospedadores y subtipos proporcionó información crucial sobre la especificidad del método. Se detectó un único agujero unidimensional ($\epsilon = 492$ a $\epsilon = 501$) que, aunque presente, probablemente representa un falso positivo por las siguientes características:

- Apareció exclusivamente entre secuencias H9N2 de pollos de Liaoning
- Las secuencias provenían de la misma región geográfica
- El período de recolección fue breve (2015-2016)
- La persistencia del agujero fue relativamente corta (9 unidades)

Sin embargo, el hallazgo más importante de este análisis no fue la presencia de este probable falso positivo, sino la ausencia total de agujeros topológicos entre secuencias de diferentes especies hospedadoras o subtipos virales. Este resultado es coherente con las restricciones biológicas conocidas para la transferencia genética horizontal en virus de influenza, donde estos eventos están limitados por barreras específicas de hospedador y compatibilidad genética. El hecho de que el método no detecte señales de transferencia horizontal entre virus de diferentes hospedadores o subtipos valida su capacidad para respetar las limitaciones biológicas naturales. Es notable que en todos los controles negativos, los agujeros topológicos detectados compartieron características que sugieren su naturaleza de falsos positivos:

- a) Fueron exclusivamente unidimensionales (H_1)
- b) Presentaron persistencia extremadamente baja (diferencias de 1-9 unidades entre tiempos de nacimiento y muerte)
- c) Aparecieron únicamente entre secuencias con alta proximidad temporal y geográfica
- d) Involucraron consistentemente secuencias del mismo hospedador y subtipo viral

La aparición consistente de falsos positivos con características específicas nos permite concluir que se deben examinar con especial cautela las señales topológicas cuando las secuencias analizadas comparten:

- Alta similitud genética
- Proximidad temporal (períodos menores a un año)
- Proximidad geográfica (misma región o provincia)
- Mismo hospedador y subtipo viral

Los resultados de los controles negativos también proporcionaron información valiosa sobre las limitaciones del método. La aparición consistente de falsos positivos en ciertos contextos, junto con la variación en el número de señales detectadas según el tamaño de la muestra, indica la necesidad de establecer protocolos rigurosos de validación y filtrado de resultados.

6.1.2. Robustez y reproducibilidad del método

La validación de cualquier método de análisis genómico requiere una evaluación exhaustiva de su robustez y reproducibilidad bajo diferentes condiciones. En este estudio, se evaluaron estos aspectos mediante múltiples estrategias experimentales que proporcionaron información valiosa sobre la fiabilidad y las limitaciones del método.

6.1.2.1. Robustez frente a variaciones en el tamaño muestral

Los experimentos de validación con diferentes tamaños muestrales revelaron aspectos cruciales sobre la robustez del método:

- Para conjuntos pequeños y medianos (6-27 secuencias), el método mostró una alta reproducibilidad en la detección del agujero bidimensional característico del reordenamiento triple en H7N9, manteniendo coordenadas de persistencia consistentes, con el agujero H_2 apareciendo en intervalos similares ($\epsilon = 1970.0$ a $\epsilon = 2027.0$).

- Sin embargo, al aumentar el tamaño a 39 secuencias, se observó una pérdida significativa de la señal del agujero bidimensional, aunque los agujeros unidimensionales (H_1) se mantuvieron detectables.
- En conjuntos grandes (54 secuencias), la complejidad adicional del espacio topológico resultó en una reducción significativa de las señales detectadas, manteniendo únicamente un agujero unidimensional.

Una hipótesis que podría explicar la pérdida de señales topológicas al incrementar el tamaño de la muestra es la posible “saturación” del espacio métrico. Al añadir nuevas secuencias, estas podrían ubicarse espacialmente dentro de las regiones que previamente formaban los agujeros topológicos. En términos geométricos, las nuevas secuencias actuarían como “puentes” entre las secuencias que originalmente formaban el agujero, reduciendo efectivamente las distancias entre ellas. Como resultado, la estructura topológica que anteriormente caracterizaba el evento de transferencia horizontal (el agujero) no llegaría a formarse, ya que las secuencias dentro de esa región estarían más densamente conectadas debido a estos nuevos puntos intermedios. Este fenómeno sería particularmente relevante en el caso del agujero bidimensional (H_2) característico del reordenamiento triple, cuya formación depende de una disposición específica de secuencias en el espacio métrico que podría verse interrumpida por la adición de puntos intermedios.

6.1.2.2. Reproducibilidad con secuencias artificiales

Para los experimentos con secuencias artificiales al introducir las variantes artificiales con una tasa de mutación del 2% y la tasa de mutación al 10% no se logró recuperar el agujero bidimensional característico del reordenamiento triple, indicando que la adición de secuencias artificiales no es suficiente para preservar señales topológicas complejas en conjuntos grandes de datos.

6.1.2.3. Implicaciones para la aplicación del método

Luego de los resultados anteriores podemos establecer las siguientes recomendaciones para la aplicación óptima del método:

- a) **Tamaño muestral óptimo:** El método muestra mayor robustez y reproducibilidad en conjuntos de 20-30 secuencias. Para conjuntos más grandes, se recomienda:
 - Realizar análisis por subconjuntos
 - Priorizar secuencias cercanas al evento de interés
 - Mantener un balance entre diversidad y tamaño muestral

Efecto de saturación en el espacio métrico



Figura 6.1: Visualización del efecto de saturación en el espacio métrico al aumentar el tamaño muestral. A la izquierda se muestra un conjunto de 4 secuencias (puntos azules) que forman un ciclo para un valor dado de ϵ . A la derecha se ilustra cómo la adición de una quinta secuencia (punto rojo) en el centro actúa como “puente”, generando múltiples triángulos que interrumpen la formación del ciclo original. Este fenómeno explica por qué las señales topológicas pueden perderse al aumentar el número de secuencias en el análisis: los nuevos puntos pueden ubicarse en posiciones que interrumpen las estructuras topológicas previamente detectables.

- b) **Estrategia de validación:** Se recomienda un enfoque multi-nivel que incluya:
- Análisis tanto de secuencias concatenadas como de segmentos individuales
 - Validación cruzada con diferentes subconjuntos de datos
 - Comparación con controles negativos apropiados

6.2. Interpretación de casos de estudio

6.2.1. Reordenamiento triple en H7N9

6.2.1.1. Análisis de la señal topológica característica

La detección del agujero bidimensional (H_2) en el análisis de secuencias concatenadas constituye la señal topológica más significativa de este estudio. Este agujero, que aparece en $\epsilon = 2027$ y desaparece en $\epsilon = 2080$, representa una estructura topológica que solo puede surgir de la interacción de al menos tres linajes parentales diferentes. La persistencia de esta señal (53 unidades) es considerablemente mayor que la observada en los falsos positivos de los controles negativos, lo que respalda su interpretación como un evento genuino de reordenamiento triple.

La presencia simultánea de un agujero unidimensional (H_1) que precede al H_2 (nacimiento en $\epsilon = 1673$ y muerte en $\epsilon = 2026$) sugiere que el reordenamiento triple pudo haber ocurrido en etapas, posiblemente involucrando eventos intermedios de reordenamiento doble antes de la incorporación del tercer componente parental. Esta observación es consistente con la naturaleza gradual de la evolución viral y sugiere que el análisis topológico puede capturar no solo el evento final sino también las etapas intermedias del proceso evolutivo.

6.2.1.2. Ventajas del método de análisis topológico

El análisis topológico demostró varias fortalezas significativas en la detección del reordenamiento triple de H7N9. Una de las principales ventajas es la capacidad de detectar simultáneamente la interacción entre las tres secuencias parentales involucradas en el reordenamiento a través de una única señal topológica característica (el agujero bidimensional), lo que simplifica significativamente el proceso de análisis y la interpretación de resultados. La ausencia de agujeros uni y bidimensionales (H_1 y H_2) en el análisis individual de los segmentos refuerza la validez de la detección, ya que confirma que estas características topológicas emergen solo

cuando se considera la estructura completa del genoma. Este hallazgo es consistente con el mecanismo biológico del reordenamiento, donde segmentos completos son intercambiados entre virus diferentes sin que ocurran modificaciones significativas dentro de cada segmento individual. Si bien el método de análisis topológico se encuentra en una etapa temprana de desarrollo, su capacidad demostrada para detectar eficientemente eventos de transferencia horizontal sugiere un potencial significativo para el estudio de la evolución viral. Las ventajas observadas en términos de rapidez de detección y simplicidad de análisis indican que, con mayor desarrollo y refinamiento, este enfoque podría convertirse en una herramienta valiosa para la vigilancia genómica viral. No obstante, es importante reconocer que el método requiere optimización adicional, particularmente en aspectos como el manejo de conjuntos de datos más grandes y la discriminación más precisa entre señales verdaderas y falsos positivos.

6.2.2. Recombinación en SARS-CoV-2

6.2.2.1. Significado biológico de los patrones detectados

Aunque nuestro análisis topológico detectó un agujero unidimensional (H_1) en la región de la proteína Spike, los resultados no coincidieron con el evento de recombinación documentado en la literatura para la variante XBB.1. Específicamente, Chakraborty et al. (4) han reportado que XBB.1 se originó a partir de un evento de recombinación entre los linajes BA.2.75 y BA.2.10.1 (BJ.1). Sin embargo, nuestro análisis no logró detectar la señal topológica esperada de este evento específico de recombinación. Esta discrepancia merece un análisis cuidadoso, por lo que proponemos varias hipótesis que podrían explicar por qué nuestro método no detectó la señal esperada:

a) Limitaciones en el muestreo:

- Es posible que las secuencias específicas que participaron directamente en el evento de recombinación no estuvieran incluidas en nuestro conjunto de datos
- La representación limitada de secuencias de cada linaje podría haber dificultado la detección de la estructura topológica característica del evento

b) Complejidad temporal del evento:

- La recombinación que dio origen a XBB.1 podría haber ocurrido en múltiples etapas, generando una estructura topológica más compleja que la que nuestro método actual puede detectar
- Las secuencias intermedias que conectan los linajes parentales podrían haberse perdido o no estar representadas en las bases de datos

c) Limitaciones metodológicas:

- El método podría ser más sensible a ciertos tipos de señales de recombinación que a otras, dependiendo de la estructura específica del evento

d) Naturaleza del evento de recombinación:

- La recombinante podría presentar una similitud genética tan alta con sus secuencias parentales que el evento de transferencia horizontal no genera una señal topológica lo suficientemente distintiva para ser detectada por el método actual

La discrepancia entre nuestros resultados y los eventos de recombinación documentados no invalida el método, sino que resalta áreas importantes para su mejora y refinamiento. Además, el agujero unidimensional que detectamos, aunque no corresponde al evento esperado, podría estar señalando otros eventos de recombinación no documentados previamente, lo que sugiere la necesidad de una investigación más detallada de estas señales.

6.2.3. Análisis de los experimentos de simulación

6.2.3.1. Validación de las señales topológicas

a) Simulación control:

- La ausencia total de agujeros topológicos en el conjunto control, tanto en el análisis de secuencias concatenadas como en el análisis por segmentos, estableció una línea base clara para la interpretación de señales en las demás simulaciones

b) Simulación de reordenamiento:

- La detección de un agujero unidimensional (H_1) específico ($\epsilon = 2133.0$ a $\epsilon = 2147.0$) en el análisis de secuencias concatenadas, junto con la ausencia de señales en el análisis individual de segmentos, representa un patrón característico del reordenamiento
- Este patrón es consistente con el mecanismo biológico del reordenamiento, donde segmentos completos son intercambiados sin modificación interna

c) Simulación de recombinación:

- La presencia de un agujero unidimensional en el análisis de secuencias concatenadas ($\epsilon = 2126.0$ a $\epsilon = 2147.0$), combinada con la detección de señales específicas en el análisis del segmento recombinante, establece un patrón distintivo para eventos de recombinación
- La necesidad de incluir secuencias intermediarias adicionales para detectar la señal de recombinación sugiere que estos eventos pueden requerir un muestreo más específico para su detección efectiva

6.2.3.2. Distinción entre reordenamiento y recombinación

Los experimentos de simulación revelaron criterios importantes para distinguir entre eventos de reordenamiento y recombinación:

a) **Análisis de secuencias concatenadas:**

- La similitud en las señales topológicas a nivel global sugiere que el análisis de secuencias concatenadas por sí solo no es suficiente para discriminar entre tipos de transferencia horizontal

b) **Análisis por segmentos:**

- La presencia o ausencia de señales topológicas en segmentos individuales emerge como el criterio más confiable para distinguir entre tipos de eventos
- El reordenamiento se caracteriza por la ausencia de señales en el análisis individual de segmentos
- La recombinación puede detectarse a través de señales específicas en el segmento afectado, especialmente cuando se incluyen secuencias intermediarias apropiadas

6.2.3.3. Implicaciones para el análisis de eventos de transferencia genética

Los resultados de las simulaciones tienen importantes implicaciones para la aplicación práctica del método:

a) **Estrategia de análisis:**

- Se recomienda un enfoque dual que combine el análisis de secuencias concatenadas con el análisis por segmentos
- La ausencia de señales en segmentos individuales no debe interpretarse automáticamente como ausencia de transferencia horizontal, sino que debe considerarse en conjunto con el análisis global

b) **Selección de secuencias:**

- La inclusión de secuencias intermediarias apropiadas es crucial, especialmente para la detección de eventos de recombinación
- El muestreo debe considerar tanto la diversidad temporal como la geográfica para maximizar la probabilidad de detectar eventos de transferencia

6.2.3.4. Consideraciones sobre la composición de secuencias recombinantes

Un aspecto importante a considerar en nuestros experimentos de simulación es la proporción específica de material genético utilizada en la construcción de la secuencia recombinante. En nuestro caso, la variante artificial se generó utilizando una distribución asimétrica de nucleótidos:

- 304 nucleótidos de A/Michigan/45/2015(H1N1)
- 1596 nucleótidos de A/Hong Kong/1968(H3N2)

Esta composición específica (aproximadamente 16 % de un parental y 84 % del otro) podría estar influenciando los patrones topológicos observados. Para una validación más completa del método, sería necesario:

a) Análisis de diferentes proporciones:

- Evaluar casos con proporciones más equilibradas (por ejemplo, 50 %-50 %)
- Examinar situaciones con contribuciones mínimas de uno de los parentales
- Analizar múltiples puntos de recombinación dentro del mismo segmento

b) Validación de robustez:

- Verificar si los agujeros unidimensionales se mantienen detectables en el análisis de secuencias concatenadas con diferentes proporciones de material genético
- Confirmar si el análisis de segmentos individuales sigue siendo efectivo para identificar recombinación con diferentes distribuciones de nucleótidos
- Determinar si existe un umbral mínimo de contribución parental necesario para la detección de señales topológicas

c) Implicaciones metodológicas:

- La capacidad del método para detectar eventos de recombinación podría variar según la proporción de material genético intercambiado
- Sería necesario establecer parámetros de detección ajustados a diferentes escenarios de recombinación
- La interpretación de resultados debería considerar la posible influencia de la composición de la secuencia recombinante

6.3. Limitaciones del método

6.3.1. Requerimientos específicos de datos

Una de las limitaciones más significativas del método radica en sus requisitos específicos de datos de entrada:

a) **Requisitos mínimos de secuencias:**

- Para eventos singulares de transferencia horizontal: mínimo 4 secuencias (parentales, resultante y una secuencia ancestral relacionada)
- Para eventos que involucran tres secuencias (como el reordenamiento triple): mínimo 6 secuencias, incluyendo:
 - Secuencias parentales
 - Secuencia resultante del evento
 - Secuencia ancestral que comparta genoma con el resultado y dos parentales
 - Secuencia que comparta genoma con todas excepto la resultante

b) **Calidad de las secuencias:**

- Necesidad de secuencias de alta calidad con mínima presencia de nucleótidos indeterminados ('N')
- Baja tolerancia a errores de secuenciación, especialmente crítica en conjuntos pequeños
- Los errores de secuenciación o anotación pueden generar tanto falsos positivos como falsos negativos

c) **Complejidad de datos:**

- Requerimiento de secuencias parentales completas
- Necesidad de secuencias intermediarias o ancestrales bien conservadas
- La ausencia de cualquiera de estos elementos puede comprometer significativamente la detección

6.3.2. Limitaciones técnicas

El método presenta varias restricciones técnicas que afectan su aplicabilidad:

a) **Sensibilidad a eventos pequeños:**

- Baja capacidad para detectar recombinaciones en segmentos genómicos muy cortos
- Posible pérdida de eventos significativos que ocurren en regiones genómicas pequeñas

- Dificultad para establecer un umbral mínimo de tamaño para la detección confiable

b) Restricciones computacionales:

- Alta demanda de recursos computacionales para conjuntos grandes de datos

6.3.3. Limitaciones de validación

Alcance de las simulaciones:

- Número limitado de secuencias y eventos artificiales analizados
- Falta de evaluación de eventos más complejos o múltiples
- Necesidad de validación con conjuntos de datos más diversos

6.3.4. Evaluación de robustez:

- La capacidad del método para distinguir entre verdaderos eventos de transferencia horizontal y variaciones genéticas naturales no ha sido completamente evaluada
- No se ha realizado un análisis sistemático del comportamiento del método cuando las secuencias contienen diferentes proporciones de nucleótidos indeterminados o errores de secuenciación
- Se requiere validar el método con más conjuntos de datos reales que incluyan:
 - Diferentes familias virales
 - Diversos contextos epidemiológicos
 - Distintas escalas temporales y geográficas
 - Variantes con diferentes tasas de mutación

6.3.5. Implicaciones para la aplicación práctica

- El método debe utilizarse en conjunto con otras técnicas de análisis genómico
- Necesidad de interpretación cautelosa de los resultados

6.4. Trabajo futuro

Los resultados y limitaciones identificadas en este estudio sugieren varias líneas de investigación futura, que abarcan desde mejoras metodológicas hasta aplicaciones más amplias del método.

6.4.1. Mejoras metodológicas y expansión del alcance

El desarrollo futuro del método debe enfocarse en dos aspectos fundamentales: optimización técnica y ampliación de aplicaciones. En términos de optimización, es prioritario desarrollar la capacidad para manejar conjuntos de datos extensos, mejorar la sensibilidad en la detección de eventos en segmentos pequeños e implementar sistemas robustos de filtrado automático de falsos positivos. Paralelamente, se busca expandir la aplicabilidad del método a otros contextos biológicos, incluyendo el análisis de diversos virus con genoma segmentado, el estudio de eventos de recombinación en diferentes familias virales, la investigación de transferencia horizontal en otros patógenos y el análisis de eventos de transferencia múltiple.

6.4.2. Validación y benchmarking

1) Estudios de simulación extendidos:

- Generación de conjuntos de datos simulados más complejos
- Evaluación sistemática de diferentes escenarios de transferencia
- Análisis de robustez frente a diferentes niveles de ruido

2) Comparación con otros métodos:

- Evaluación comparativa con métodos filogenéticos establecidos
- Análisis de complementariedad con otras técnicas
- Desarrollo de protocolos integrados de análisis

Código y recursos computacionales

Todo el código desarrollado y utilizado en este trabajo está disponible públicamente en el siguiente repositorio de GitHub:

<https://github.com/JSbmath/Biomatematicas/>

A.0.1. Estructura del repositorio

El repositorio está organizado en los siguientes directorios principales:

- `/Experimentos_de_validacion/`: Contiene los experimentos realizados para validar el método
 - `Control_negativo/`: Análisis de controles negativos
 - Análisis de cepas cercanas
 - Análisis de cepas distantes
 - Comparación InfluenzaA e InfluenzaB
 - Secuencias artificiales
 - `Deteccion_con_variacion_del_tamaño/`: Experimentos con diferentes tamaños muestrales
 - `Simulacion/`: Experimentos de simulación controlada
- `/H7N9_Reordenamiento_Triple/`: Análisis del caso de estudio principal
 - `Programas_utilizados/`: Scripts específicos para este análisis
 - `Resultados/`: Outputs del análisis
 - `Secuencias/`: Datos genómicos utilizados
 - `Visualizacion/`: Contiene el notebook principal de visualización interactiva. El notebook es accesible a través de Binder, una plataforma que permite ejecutar el programa en línea sin necesidad de instalar librerías localmente. Esta herramienta facilita la reproducibilidad de los resultados y permite a otros investigadores explorar interactivamente el análisis del reordenamiento triple.
- `/XBB.1_SarsCov2/`: Análisis de recombinación en SARS-CoV-2

Bibliografía

- [1] Asaad, A. and Jassim, S. (2017). Topological data analysis for image tampering detection. In Kraetzer, C., Shi, Y., Dittmann, J., and Kim, H., editors, *Digital Forensics and Watermarking*, volume 10431 of *Lecture Notes in Computer Science*, Cham. Springer.
- [2] Brown, T. A. (2023). *Genomes 5*. CRC Press, Boca Raton, 5 edition.
- [3] Centers for Disease Control and Prevention (2023). Tipos de virus de influenza. Accessed: 28 February 2024.
- [4] Chakraborty, C., Bhattacharya, M., Chopra, H., Islam, M. A., Saikumar, G., and Dhama, K. (2023). The sars-cov-2 omicron recombinant subvariants xbb, xbb.1, and xbb.1.5 are expanding rapidly with unique mutations, antibody evasion, and immune escape properties – an alarming global threat of a surge in covid-19 cases again? *International Journal of Surgery*, 109:1041–1043.
- [5] Chan, J. M., Carlsson, G., and Rabadan, R. (2013). Topology of viral evolution. *Proceedings of the National Academy of Sciences*, 110(46):18566–18571.
- [6] Cock, P. J., Antao, T., Chang, J. T., Chapman, B. A., Cox, C. J., Dalke, A., Friedberg, I., Hamelryck, T., Kauff, F., Wilczynski, B., et al. (2009). Biopython: freely available python tools for computational molecular biology and bioinformatics. *Bioinformatics*, 25(11):1422–1423.
- [7] Dangi, T. and Jain, A. (2012). Influenza virus: A brief overview. *Proceedings of the National Academy of Sciences, India Section B: Biological Sciences*, 82(1):111–121.
- [8] Edelsbrunner, H. and Harer, J. (2010). *Computational Topology: An Introduction*. American Mathematical Society, Providence, Rhode Island.

- [9] European Bioinformatics Institute (2023). Clustal omega - multiple sequence alignment (msa). <https://www.ebi.ac.uk/jdispatcher/msa/clustalo>.
- [10] Flint, S. J., Enquist, L. W., Racaniello, V. R., Rall, G. F., and Skalka, A. M. (2015). *Principles of Virology*. ASM Press, Washington, DC, 4th edition. 2 Volume Set, Chapter 1.
- [11] Fugacci, U., Scaramuccia, S., Iuricich, F., and De Florian, L. (2016). Persistent homology: a step-by-step introduction for newcomers. *Smart Tools and Apps in computer Graphics (STAG)*.
- [12] Gao, R., Cao, B., Hu, Y., Feng, Z., Wang, D., Hu, W., Chen, J., Jie, Z., Qiu, H., Xu, K., Xu, X., Lu, H., Zhu, W., Gao, Z., Xiang, N., Shen, Y., He, Z., Gu, Y., Zhang, Z., Yang, Y., Zhao, X., Zhou, L., Li, X., Zou, S., Zhang, Y., Li, X., Yang, L., Guo, J., Dong, J., Li, Q., Dong, L., Zhu, Y., Bai, T., Wang, S., Hao, P., Yang, W., Zhang, Y., Han, J., Yu, H., Li, D., Gao, G. F., Wu, G., Wang, Y., Yuan, Z., and Shu, Y. (2013). Human infection with a novel avian-origin influenza A (H7N9) virus. *New England Journal of Medicine*, 368(20):1888–1897.
- [13] Genome.gov (2024). Human genome reference sequence. Accessed: 28 February 2024.
- [14] GISAID Initiative (2023). Gisaids - global initiative on sharing all influenza data. <https://www.gisaid.org/>.
- [15] Heydenreich, S., Brück, B., and Harnois-Déraps, J. (2021). Persistent homology in cosmic shear: Constraining parameters with topological data analysis. *A&A*, 648:A74.
- [16] Hu, B., Guo, H., Zhou, P., and Shi, Z.-L. (2021). Characteristics of sars-cov-2 and covid-19. *Nature Reviews Microbiology*, 19(3):141–154.
- [17] ICTV (2011). Orthomyxoviridae. Accessed: 28 February 2024.
- [18] Lai, M. M. (1992). Rna recombination in animal and plant viruses. *Microbiological Reviews*, 56(1):61–79.
- [19] Li, F. (2016). Structure, function, and evolution of coronavirus spike proteins. *Annual Review of Virology*, 3(1):237–261.
- [20] Lowen, A. C. (2018). It’s in the mix: Reassortment of segmented viral genomes. *PLoS Pathogens*, 14(7):e1007200.
- [21] McDonald, S. M., Nelson, M. I., Turner, P. E., and Patton, J. T. (2016). Reassortment in segmented rna viruses: mechanisms and outcomes. *Nature Reviews Microbiology*, 14(7):448–460.

- [22] Munch, E. (2017). A user’s guide to topological data analysis. *Journal of Learning Analytics*, 4(2):47–61.
- [23] Murphy, B. R. and Webster, R. G. (1996). Orthomyxovirus. In Fields, B. N. et al., editors, *Virology*, pages 1397–1445. Lippincott-Raven Publishers.
- [24] National Center for Biotechnology Information (2023). Ncbi. <https://www.ncbi.nlm.nih.gov/>.
- [25] Nextclade team (2024). Nextclade: clade assignment, mutation calling, and quality control for viral genomes. Accessed: 14 July 2024.
- [26] Nextstrain team (2024). Genomic epidemiology of sars-cov-2 with sub-sampling focused globally over the past 6 months. Accessed: 28 February 2024.
- [27] P’erez-Losada, M., Arenas, M., Gal’an, J. C., Palero, F., and Gonz’alez-Candelas, F. (2015). Recombination in viruses: mechanisms, methods of study, and evolutionary consequences. *Infection, Genetics and Evolution*, 30:296–307.
- [28] Postol., M. S. (2023). *Algebraic Topology for Data Scientists*. The MITRE Corporation.
- [29] Project, T. G. (2015). *GUDHI User and Reference Manual*. GUDHI Editorial Board.
- [30] Rabadan, R. (2016). Inference of ancestral recombination graphs through topological data analysis. *PLOS Computational Biology*, 12(8):e1005071.
- [31] Rabadan, R. and Blumberg, A. J. (2020). *Topological Data Analysis for Genomics and Evolution: Topology in Biology*. Cambridge University Press, Cambridge, United Kingdom.
- [32] Singh, Y., Farrelly, C., Hathaway, Q., et al. (2023). Topological data analysis in medical imaging: current state of the art. *Insights Imaging*, 14:58.
- [33] Steel, J. and Lowen, A. C. (2014). Influenza a virus reassortment. *Current Topics in Microbiology and Immunology*, 385:377–401.
- [34] Thiry, E., Meurens, F., Muylkens, B., McVoy, M., Gogev, S., Thiry, J., Vanderplasschen, A., Epstein, A., Keil, G., and Schynts, F. (2005). Recombination in alphaherpesviruses. *Reviews in Medical Virology*, 15(2):89–103.

BIBLIOGRAFÍA

- [35] Uribe, H. (2008). El virus influenza y la gripe aviar. *Acta Médica Costarricense*, 50(1).
- [36] U.S. National Library of Medicine (2024). What is a gene? Last updated May 21, 2024.
- [37] Waggner, B. (1995). *Pulse Code Modulation Techniques*. Springer.
- [38] Wasserman, L. (2018). Topological data analysis. *Annual Review of Statistics and Its Application*, 5:501–532.
- [39] Worobey, M. and Holmes, E. C. (2011). Evolutionary aspects of recombination in rna viruses. *Journal of General Virology*, 92(4):751–761.
- [40] Wu, A., Su, C., Wang, D., Peng, Y., Liu, M., Hua, S., Li, T., Gao, G. F., Tang, H., Chen, J., Liu, X., Shu, Y., Peng, D., and Jiang, T. (2013). Sequential Reassortments Underlie Diverse Influenza H7N9 Genotypes in China. *Cell Host & Microbe*, 14(4):446–452.
- [41] Zhu, N., Zhang, D., Wang, W., Li, X., Yang, B., Song, J., Zhao, X., Huang, B., Shi, W., Lu, R., Niu, P., Zhan, F., Ma, X., Wang, D., Xu, W., Wu, G., Gao, G. F., Tan, W., and China Novel Coronavirus Investigating and Research Team (2020). A novel coronavirus from patients with pneumonia in china, 2019. *New England Journal of Medicine*, 382(8):727–733.